

北京理工大学

本科生毕业设计（论文）

面向代码变更的多智能体回归测试用例生成
方法

Multi-agent Regression Test Case Generation Method for Code
Changes

学 院： 计算机学院

专 业： 人工智能

班 级： 07162202

学生姓名： 王穆祺

学 号： 1120222608

指导教师： 赵三元

2026 年 5 月 12 日

原创性声明

特此申明。

本人签名: _____ 日期: _____ 年 _____ 月 _____ 日

关于使用授权的声明

本人签名: _____ 日期: _____ 年 _____ 月 _____ 日

指导老师签名: _____ 日期: _____ 年 _____ 月 _____ 日

面向代码变更的多智能体回归测试用例生成方法

摘 要

回归测试是保障软件迭代质量的关键环节，然而现有方法在变更感知精准度、测试生成效率与用例质量之间难以取得平衡。传统基于搜索或变异的自动化测试工具缺乏对代码变更语义的理解，生成的测试用例缺乏针对性；单 Agent 方案虽能利用大语言模型生成高质量用例，但存在用例冗余、缺乏质量闭环等问题。

本文提出并实现了一个面向代码变更的多智能体回归测试用例生成系统。该系统以 LangGraph 为编排框架，协调 12 个专业化 Agent 节点，形成“规则为主、LLM 为辅”的混合架构：代码变更解析 Agent 以 Tree-sitter 和启发式规则提取变更实体与符号级分析；影响分析 Agent 基于变更解构图（file/symbol/seed/focus 四类节点）与语义单元驱动的 seed/tag 关联实现精准影响传播推理；测试生成 Agent 通过 compile 校验—LLM 重试—占位兜底三重机制保障用例可执行性；测试修复 Agent 以语法/导入/已知模式修复形成闭环。各模块通过可配置开关灵活启用，支持效率与效果偏好调整。

在 typer 项目上的实验结果表明，本文方法在变更感知场景下实现了 93%–96% 的测试压缩率和 78%–96% 的执行时间缩减率，Bug 检测率达 90% 而基线方法均为 0%。覆盖率效率比（每用例覆盖率贡献）是 Single-Agent 的 1.33–1.85 倍，utils 模块上时间效率比达 2.2 倍。消融实验验证了各组件的不可替代性：移除 LLM 使变更覆盖率下降 56.8%，移除 TestRepair 使通过率从 72.63% 骤降至 37.86%。

关键词：回归测试；多智能体系统；代码变更影响分析；大语言模型；测试用例自动生成

关键词：北京理工大学；本科生；毕业设计（论文）——请在“main.tex”开头设置

Multi-agent Regression Test Case Generation Method for Code Changes

Abstract

Regression testing is a critical 环节 in safeguarding software quality during iterative development. However, existing methods struggle to balance change-aware precision, test generation efficiency, and test case quality. Traditional search-based or mutation-based automated testing tools lack understanding of code change semantics, producing tests with insufficient targeting. Single-agent approaches leverage large language models (LLMs) to generate high-quality cases but suffer from case redundancy and the absence of a quality assurance loop.

This thesis proposes and implements a multi-agent regression test case generation system oriented toward code changes. The system employs LangGraph as the orchestration framework, coordinating 12 specialized agent nodes in a hybrid “rules-primary, LLM-augmented” architecture. The code change analysis agent extracts change entities and symbol-level analysis using Tree-sitter and heuristic rules. The impact analysis agent achieves precise impact propagation reasoning based on a change decomposition graph (with four node types: file, symbol, seed, and focus) and semantic unit-driven seed/tag association. The test generation agent ensures case executability through a three-tier mechanism: compile verification, LLM retry, and placeholder fallback. The test repair agent forms a closed loop with syntax, import, and known-pattern fixes. All modules can be flexibly enabled via configurable switches, supporting preference-based adjustment between efficiency and effectiveness.

Experimental results on the typer project demonstrate that the proposed method achieves 93%–96% test compression rates and 78%–96% execution time reduction rates in change-aware scenarios, with a bug detection rate of 90% compared to 0% for all baselines. The coverage efficiency ratio (coverage contribution per test case) is 1.33–1.85 times that of the single-agent approach, and the time efficiency ratio on the utils module reaches 2.2 times. Ablation experiments verify the indispensability of each component: removing LLM reduces change coverage by 56.8%, and removing TestRepair drops the pass rate from 72.63% to 37.86%.

Keywords: regression testing; multi-agent system; code change impact analysis; large language model; automated test case generation

Key Words: BIT; Undergraduate; Graduation Project (Thesis)

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 软件测试自动化研究现状	2
1.2.2 代码变更影响分析研究	3
1.2.3 多智能体与大模型在软件工程中的应用	4
1.3 本文主要研究内容	5
1.4 本文组织架构	6
第 2 章 相关技术与方法	7
2.1 软件测试相关技术	7
2.1.1 单元测试与集成测试	7
2.1.2 自动化测试框架（Pytest）	7
2.2 代码变更分析技术	8
2.2.1 Unified Diff 解析	8
2.2.2 代码变更图与依赖关系建模	8
2.2.3 代码语义表示方法（AST 与 LLM）	9
2.3 多智能体系统技术	10
2.3.1 基于 LangGraph 的工作流建模	10
2.3.2 多 Agent 协同机制	10
2.4 大语言模型技术	11
2.4.1 代码理解与结构化生成	11
2.4.2 测试用例生成与修复	11
第 3 章 基于代码变更的影响分析方法	13
3.1 问题定义与总体架构	13
3.1.1 问题定义	13
3.1.2 核心理念：结构化中间表示	13
3.1.3 总体架构设计	14
3.2 代码变更信息提取	15
3.2.1 Unified Diff 解析与结构化	15

3.2.2 变更文件与代码块建模	16
3.2.3 变更实体抽取与符号级分析	17
3.3 变更解构图构建	18
3.3.1 节点与边的定义	19
3.3.2 变更解构图构建方法	19
3.4 语义单元建模方法	19
3.4.1 原子语义单元定义	21
3.4.2 语义标签体系	22
3.4.3 语义单元提取方法	22
3.5 影响传播与风险评估模型	23
3.5.1 基于种子与标签的传播机制	23
3.5.2 风险评分与优先级量化	24
3.6 影响分析结果生成与结构化输出	25
3.6.1 结构化输出设计	25
3.6.2 与下游模块的接口规范	27
第4章 多智能体测试生成系统设计与实现	28
4.1 系统总体架构设计	28
4.1.1 系统总体架构	28
4.1.2 多智能体协同流程	29
4.1.3 质量门控机制	30
4.2 核心 Agent 模块设计	32
4.2.1 变更理解阶段	32
4.2.2 测试规划阶段	33
4.2.3 测试生成阶段	35
4.2.4 测试修复阶段	36
4.2.5 评估反馈阶段	37
4.3 测试生成策略	38
4.3.1 基于变更的测试策略	38
4.3.2 结构化中间表示传递	39
4.4 系统实现	40
4.4.1 技术栈与开发环境	40
4.4.2 核心模块实现	40
4.4.3 错误处理与质量保障	41

4.4.4 工程化保障措施	41
4.5 Web 工作台与结果可视化	42
4.5.1 系统接口设计	42
4.5.2 用户交互流程	43
4.5.3 结果可视化设计	44
第 5 章 系统测试与实验分析	48
5.1 实验环境与数据集	48
5.1.1 实验环境配置	48
5.1.2 实验数据集	48
5.1.3 Baseline 工具	48
5.2 评价指标	49
5.2.1 测试覆盖率指标	49
5.2.2 测试质量指标	49
5.2.3 测试效率指标	50
5.2.4 测试选择效果指标	50
5.3 对比实验设计	50
5.3.1 实验 A：单模块测试生成对比	51
5.3.2 实验 B：多模块变更感知测试对比	51
5.4 实验 A——单模块测试生成对比	52
5.4.1 测试覆盖率对比	52
5.4.2 测试通过率对比	53
5.4.3 测试效率对比	54
5.4.4 覆盖率效率分析	55
5.4.5 实验 A 小结	57
5.5 实验 B——多模块变更感知测试对比	58
5.5.1 实验设计与提交选取	58
5.5.2 变更覆盖率对比	58
5.5.3 Bug 检测能力对比	60
5.5.4 测试压缩与执行缩减	61
5.5.5 实验 B 小结	62
5.6 消融实验结果分析	62
5.6.1 各模块贡献度分析	62
5.6.2 自修复能力消融实验	64

5.6.3 LLM 能力消融实验	65
5.7 实验结果讨论	67
5.7.1 方法优势分析	67
5.7.2 局限性分析	68
5.8 本章小结	68
结 论	70
参考文献	73
附 录	76
附录 A L ^A T _E X 环境的安装	76
附录 B BITHesis 使用说明	76
致 谢	77

第 1 章 绪论

1.1 研究背景与意义

随着软件产业的快速发展，软件系统的规模与复杂度持续增长，软件质量保障面临前所未有的挑战。软件测试作为保证软件质量的关键环节，在软件开发生命周期中占据重要地位。然而，传统软件测试过程高度依赖人工经验，存在效率低、覆盖不足、成本高等问题。据统计，软件测试环节平均消耗整个开发周期 40%-50% 的时间与资源，在安全关键系统中甚至高达 60%-80%[1]。如何提高测试效率、降低测试成本、保证测试质量，成为软件工程领域亟待解决的重要问题。

近年来，敏捷开发与持续集成（Continuous Integration, CI）模式在软件开发中得到广泛应用，代码变更更加频繁，迭代周期显著缩短。在此背景下，回归测试成为保证软件质量的重要手段。传统的回归测试主要依赖人工编写测试用例，不仅耗时耗力，而且难以快速响应频繁的代码变更。研究表明，开发人员平均需要花费 20%-30% 的工作时间编写和维护测试用例。此外，人工测试用例的质量高度依赖测试人员的经验与技能，存在覆盖不全面、测试点遗漏等问题，难以有效保证测试的有效性与充分性。

代码变更影响分析是回归测试的核心环节之一，其目标在于识别代码变更可能影响的系统范围，从而指导测试资源的分配与测试用例的生成。传统的代码变更分析方法主要基于文本差异比较，仅能识别行级变化，难以反映代码的真实语义与影响范围。例如，当函数内部逻辑发生重构或接口参数发生变化时，仅凭文本差异难以准确识别其对其他模块的影响。这种语义层面的信息缺失，导致测试覆盖不全面或过度测试，影响测试效率与质量。

近年来，人工智能技术，特别是大语言模型（Large Language Model, LLM）与多智能体系统（Multi-Agent System, MAS）的快速发展，为软件测试自动化带来了新的机遇。大语言模型在代码理解、自然语言处理、知识推理等方面展现出强大的能力，为测试用例的自动生成提供了新的技术路径。多智能体系统通过多个 Agent 的协同决策与任务分工，能够处理复杂、多步骤的任务，提高系统的智能化水平与可扩展性[2]。将大语言模型与多智能体系统相结合，有望实现从代码变更分析到测试用例生成的端到端自动化，显著提升软件测试的效率与质量。

基于上述背景，本课题围绕基于多智能体的软件测试自动化与智能决策方法展开研究，旨在解决传统软件测试过程中对人工经验依赖强、测试覆盖不足及效率较低等问题。通过引入代码语义分析技术与多 Agent 协同机制，实现从代码变更到测试用例生成的自动化与智能化。本研究的意义主要体现在以下几个方面：

(1) 理论意义。本研究将代码语义分析、影响分析、缺陷模式挖掘与大语言模型、多智能体系统相结合，提出一种新的软件测试自动化框架，丰富了软件测试自动化与智能化研究的理论体系。

(2) 技术意义。本研究提出的基于多智能体的测试生成方法，能够有效提升测试用例生成的自动化程度与智能化水平，降低对人工经验的依赖，提高测试效率与质量，具有重要的技术价值。

(3) 应用价值。本研究成果可应用于持续集成环境下的回归测试场景，支持快速迭代开发模式，帮助开发团队及时发现与修复缺陷，降低软件维护成本，具有广阔的应用前景。

1.2 国内外研究现状

1.2.1 软件测试自动化研究现状

软件测试自动化是软件工程领域的重要研究方向，其目标是通过自动化工具与技术，减少或替代人工测试工作，提高测试效率与质量。根据自动化程度的不同，软件测试自动化可分为测试脚本自动化、测试用例生成自动化与测试执行自动化等层次。

在测试用例自动生成方面，传统方法主要分为基于搜索的方法（Search-Based Software Testing, SBST）与基于模型的方法（Model-Based Testing, MBT）[3]。基于搜索的方法通过优化算法（如遗传算法、模拟退火算法等）在测试用例空间中搜索，以最大化覆盖率或最小化测试数量为目标，自动生成测试用例。代表性工具包括 Pynguin、EvoSuite 等。Pynguin 是针对 Python 语言的单元测试生成工具，采用遗传算法优化测试用例生成过程，支持多种覆盖准则[4]。EvoSuite 是面向 Java 语言的测试生成工具，采用遗传算法与分支覆盖准则，生成满足特定覆盖目标的测试用例。然而，基于搜索的方法主要关注覆盖率指标，生成的测试用例往往缺乏语义合理性，可读性与可维护性较差。

基于模型的方法通过构建软件系统的形式化模型（如状态机、Petri 网等），基于

模型自动生成测试用例。此类方法需要人工构建模型，工作量大且难以适应频繁的代码变更，在实际应用中存在一定局限性。

近年来，随着深度学习与自然语言处理技术的发展，基于神经网络的测试用例生成方法逐渐受到关注。此类方法通过训练神经网络模型，学习代码与测试用例之间的映射关系，从而自动生成测试用例。代表性工作包括 A3Test、ATLAS 等[5]。然而，此类方法需要大量标注数据进行训练，且生成的测试用例质量依赖于训练数据的质量，泛化能力有待提升。

大语言模型的出现为测试用例自动生成带来了新的可能。GPT-4、Claude 等大语言模型在代码理解与生成方面展现出强大的能力，能够根据代码或需求描述生成测试用例。研究表明，基于大语言模型的测试生成方法在测试质量与可读性方面优于传统方法，但仍存在生成结果不稳定、缺乏约束与验证等问题[6]。

1.2.2 代码变更影响分析研究

代码变更影响分析是软件维护与回归测试的重要环节，其目标在于识别代码变更可能影响的系统范围，从而指导测试资源的分配与回归测试的选择[7]。根据分析方法的不同，代码变更影响分析可分为静态分析与动态分析两大类。

静态分析方法通过分析代码的结构信息（如控制流、数据流、调用关系等），推断代码变更的影响范围。代表性工作包括 Horwitz 等提出的基于系统依赖图（System Dependency Graph, SDG）的影响分析方法[8] 和 Ren 等提出的 Chianti[9]。Horwitz 等的方法通过构建系统依赖图，利用控制依赖与数据依赖关系分析代码变更对其他模块的影响传播路径。Chianti 通过将代码变更分解为原子变更集合，并结合调用图分析识别受影响的测试用例。静态分析方法的优点在于无需执行程序，分析成本低，但存在误报率较高的问题，难以准确识别动态绑定、反射调用等场景下的影响。

动态分析方法通过执行程序并收集运行时信息（如实际调用路径、数据依赖等），识别代码变更的影响范围。代表性工作包括 Daikon[10] 和 Jalangi[11]。Daikon 通过动态检测程序不变量，推断代码变更可能违反的约束条件。Jalangi 基于动态分析技术，收集 JavaScript 程序的执行轨迹，支持变更影响分析与回归测试选择。动态分析方法的优点在于分析结果较为准确，但需要执行测试用例，分析成本较高，且依赖于测试用例的覆盖率。

近年来，研究者开始将静态分析与动态分析相结合，构建混合式影响分析方法。

代表性工作包括 Chianti 与 Ekstazi 等[9, 12]。Chianti 通过静态分解识别变更影响范围, 再通过动态调用图验证影响是否真实发生。Ekstazi 在静态依赖分析的基础上, 结合代码覆盖率信息进行回归测试选择, 有效降低了测试执行成本。然而, 现有影响分析方法主要关注代码结构层面的影响, 对代码语义层面的影响识别能力有限。例如, 当函数内部逻辑发生重构时, 结构层面的变更可能较小, 但对系统行为的影响可能较大。如何将语义信息融入影响分析过程, 提高影响分析的准确性, 是当前研究的难点之一。

1.2.3 多智能体与大模型在软件工程中的应用

多智能体系统是由多个智能体组成的分布式系统, 各智能体通过协同决策与任务分工, 共同完成复杂任务。多智能体系统具有自治性、协作性、适应性等特点, 在复杂系统建模、任务规划、决策支持等领域得到广泛应用。

近年来, 多智能体系统在软件工程中的应用逐渐受到关注。代表性工作包括 AutoGen、MetaGPT 等[13-14]。AutoGen 是微软提出的通用多智能体框架, 支持多个大语言模型 Agent 之间的对话与协作, 可应用于代码生成、测试、调试等场景。MetaGPT 是面向软件开发的多智能体系统, 通过模拟软件开发团队的角色分工 (如产品经理、架构师、工程师等), 实现需求分析、设计、编码、测试等任务的自动化。此类工作展示了多智能体系统在软件工程领域的应用潜力, 但主要集中在代码生成与需求分析环节, 在测试用例生成方面的研究较少。

大语言模型在软件工程中的应用近年来取得显著进展。在测试生成方面, 研究者开始探索基于大语言模型的测试用例生成方法。代表性工作包括 CoditT5、ChatTester 等[15]。CoditT5 基于 CodeT5 模型, 根据代码变更自动生成测试用例。ChatTester 基于 ChatGPT, 通过多轮对话方式引导测试用例的生成与优化。

然而, 现有研究主要将大语言模型作为单一组件使用, 缺乏多组件之间的协同机制。在实际的测试生成过程中, 需要经过代码变更分析、影响分析、测试规划、测试生成等多个环节, 单一模型难以有效处理所有环节。如何构建多智能体协同框架, 实现各环节之间的信息流转与任务联动, 是当前研究的空白。

综上所述, 现有研究在测试自动化、影响分析、大语言模型应用等方面取得了一定进展, 但仍存在以下不足: (1) 传统测试自动化方法主要关注覆盖率指标, 缺乏对测试语义合理性的考虑; (2) 现有影响分析方法主要关注结构层面, 对语义层面

的影响识别能力有限；（3）大语言模型在测试生成中的应用主要采用单一模型，缺乏多组件协同机制。针对上述问题，本课题提出基于多智能体的软件测试自动化方法，通过代码语义分析、影响分析、缺陷模式挖掘与大语言模型、多智能体系统的深度融合，实现从代码变更到测试用例生成的端到端自动化。

1.3 本文主要研究内容

本课题围绕基于多智能体的软件测试自动化与智能决策方法展开研究，主要研究内容包括以下五个方面：

（1）代码变更分析方法研究。传统基于文本差异的代码分析方法仅能识别行级变化，难以反映代码的真实语义。本研究引入抽象语法树（AST）与 Tree-sitter 技术，对源代码进行语法级解析，将非结构化代码转换为结构化表示[16]。在此基础上，对变更内容进行语义级建模，识别函数、类、接口及变量等关键程序实体的变化，实现从“文本变更”向“语义变更”的转化，为后续分析提供可靠基础。

（2）影响分析模型设计。为准确评估代码变更的影响范围，构建基于调用关系与依赖关系的影响分析模型。调用关系（Call Graph）用于描述函数或方法之间的调用路径，当底层函数发生变更时，可沿调用链向上追溯受影响的上层模块；依赖关系分析涵盖模块依赖、类依赖及数据依赖等，用于识别因接口或数据变化引发的连锁影响[8, 17]。通过结合调用关系传播路径与依赖关系分析，构建完整的变更影响传播链路，实现从局部变更到全局影响范围的推导。

（3）缺陷模式挖掘与融合机制。为提升测试的针对性与有效性，引入历史缺陷数据，对典型缺陷进行模式化建模（Bug Pattern）。通过分析历史缺陷记录，总结常见缺陷特征，构建缺陷模式库。在实际应用中，将代码变更与缺陷模式进行匹配，从而识别潜在风险点，并指导测试重点的确定。

（4）测试规划与用例生成方法。在获取代码变更信息、影响范围及缺陷模式后，设计测试规划 Agent 进行统一决策。该模块通过融合多源信息生成测试策略，并进一步细化为具体测试点。在此基础上，结合大语言模型与 Prompt 工程方法，将测试点转化为结构化测试用例，包括测试步骤、输入数据及预期结果等[18]。

（5）多智能体协同框架设计。为提升系统整体智能化水平，构建多智能体协同框架。各 Agent 分别负责代码变更分析、影响分析、测试规划等功能，并通过统一状态管理机制进行调度。在该框架下，各 Agent 共享上下文信息并协同决策，实现信息

闭环与任务联动，从而提高系统整体的分析能力与扩展性。

1.4 本文组织架构

本文共分为五章，各章节内容安排如下：

第一章为绪论。介绍研究背景与意义，分析国内外研究现状，阐述本文的主要研究内容与组织架构。

第二章为相关技术基础。介绍本研究涉及的关键技术，包括代码分析技术（AST、Tree-sitter）、影响分析方法（调用图、依赖分析）、大语言模型与 Prompt 工程、多智能体系统框架（LangGraph）等，为后续章节提供技术支撑。

第三章为系统总体设计。阐述系统的总体架构与设计原则，介绍系统的核心模块及其相互关系，描述数据流与控制流的设计，说明关键技术选型与实现方案。

第四章为关键技术与实现。详细阐述各核心模块的设计与实现，包括代码变更分析模块、影响分析模块、缺陷模式匹配模块、测试用例生成模块、多智能体协同框架等，并给出关键技术细节与实现方案。

第五章为实验与结果分析。介绍实验设计，包括实验对象、评估指标、对比方法等，展示实验结果并进行深入分析，验证所提方法的有效性，讨论实验结果的意义与局限性。

结论部分对全文进行总结与展望：归纳研究工作与主要贡献，分析研究局限，并提出未来研究方向。

各章节之间的逻辑关系如下：第一章阐述研究背景与目标，第二章提供技术基础，第三章给出系统总体设计方案，第四章详细实现各核心模块，第五章通过实验验证方法有效性；结论部分在此基础上总结全文并展望未来工作。

第 2 章 相关技术与方法

2.1 软件测试相关技术

2.1.1 单元测试与集成测试

单元测试（Unit Testing）是软件测试体系中最基础的测试级别，其核心目标是对软件中的最小可测试单元进行验证 [1]。在面向对象编程范式下，单元通常指一个函数、一个类或一组紧密相关的函数集合。单元测试具有以下典型特征：每个测试用例应具有原子性，专注于验证单一功能点；测试用例之间应相互独立，避免共享状态导致测试结果的相互影响；单元测试应在隔离环境中执行，通过模拟（Mock）或桩（Stub）技术排除对外部依赖的依赖。单元测试的优势在于能够快速定位缺陷，降低调试成本，同时也是代码重构的重要保障。

集成测试（Integration Testing）旨在验证多个软件模块或组件之间交互的正确性 [1]。与单元测试不同，集成测试关注的是模块接口、调用协议、数据交换及集成后的系统行为。集成测试能够发现模块接口不匹配、数据格式不一致、调用时序错误等问题，是单元测试与系统测试之间的重要桥梁。在持续集成（Continuous Integration, CI）环境中，集成测试通常配置为自动化执行，及时发现代码集成过程中引入的缺陷。

在回归测试场景中，单元测试与集成测试具有互补作用。单元测试用于验证代码变更对单个函数或类的影响，侧重于局部正确性验证；集成测试则用于验证代码变更对模块间协作的影响，侧重于全局行为验证 [19]。本研究聚焦于面向代码变更的回归测试用例生成，需要同时考虑单元测试级别与集成测试级别的用例生成。

2.1.2 自动化测试框架（Pytest）

Pytest 是 Python 生态中应用最为广泛的自动化测试框架之一，以其简洁的 API 设计、强大的插件生态及丰富的功能特性著称 [20]。相较于 Python 标准库中的 unittest 框架，Pytest 采用更加灵活的设计理念，支持基于函数的测试用例定义，降低了测试代码的编写门槛。Pytest 的核心设计原则包括：约定优于配置、失败即停、以及详细的断言重写。

Pytest 的 Fixture 机制是其最具特色的功能之一，Fixture 用于提供测试所需的上

下文环境或依赖资源，支持多种作用域（function、class、module、session）及参数化配置 [20]。此外，社区提供 `pytest-asyncio`、`pytest-mock`、`pytest-xdist` 等大量插件。本研究基于 `Pytest` 构建测试执行环境。

2.2 代码变更分析技术

2.2.1 Unified Diff 解析

代码变更分析的第一步是对版本控制系统产生的差异文件进行解析。`Git` 作为目前最流行的分布式版本控制系统，其差异输出格式（`Diff Format`）是代码变更分析领域的事实标准 [21]。`Git Diff` 采用 `Unified Diff` 格式进行展示，新增行以前缀 `+` 标识，删除行以前缀 `-` 标识，上下文行以空格前缀标识。

`Python` 标准库中的 `difflib` 模块提供了差异计算的基础功能 [22]。为实现符合 `Unified Diff` 规范的解析与处理，社区广泛使用 `Python` 包 `unidiff`，该库提供了从统一差异格式到结构化数据模型的双向转换能力 [23]。通过 `unidiff`，开发者可将原始 `Diff` 文本解析为包含 `PatchedFile`、`SourceFile`、`Hunk` 等对象的数据结构，每个对象封装了文件路径、变更块起止位置、具体变更行等属性信息。

`Unified Diff` 解析在实际应用中面临若干技术挑战：变更块的重叠与合并问题、二进制文件与文件重命名的处理、编码与换行符问题等。本研究在代码变更解析模块中集成了 `Unified Diff` 解析功能，用于将 `Git` 提交产生的差异文件转换为结构化的变更表示。

2.2.2 代码变更图与依赖关系建模

代码变更的影响分析需要借助程序结构模型来追踪变更的传播路径。程序依赖图（`Program Dependence Graph, PDG`）是这一领域最具代表性的表示模型 [24]。`PDG` 将程序的控制流依赖与数据流依赖统一建模，通过 `PDG` 可以精确追踪程序中任意语句对其他语句的影响范围。

调用图（`Call Graph`）是描述函数或方法调用关系的重要模型 [25]。在调用图中，节点表示函数实体，有向边表示调用关系。调用图可分为静态调用图和动态调用图两种类型。静态调用图通过解析代码中的函数调用表达式构建，覆盖所有可能的调用路径；动态调用图则记录程序实际执行过程中的调用序列，覆盖范围有限但准确性更高。在变更影响分析中，调用图支持自底向上的影响传播。

除调用关系外，依赖关系还包括模块依赖、类依赖及数据依赖等多种类型 [26]。本研究构建了综合依赖模型，整合调用图、控制流依赖与数据流依赖等多种关系表示，通过图遍历算法实现变更影响范围的有效识别。

影响分析方法可分为基于覆盖率的测试选择与基于传播的变更影响分析两类 [7]。基于覆盖率的方法通过比较变更前后的代码覆盖率差异来确定受影响的测试用例集 [27]。基于传播的方法则从变更点出发，沿程序依赖关系图进行传播，识别所有直接或间接受影响的程序实体 [28]。本研究综合采用两类方法。

2.2.3 代码语义表示方法（AST 与 LLM）

代码的结构化表示是进行语义级代码分析的基础。抽象语法树（Abstract Syntax Tree, AST）将源代码转换为树形结构，其中每个节点对应源代码中的一个语法构造 [29]。AST 在保留代码语法结构的同时移除了无关的格式信息，使得程序分析可以在结构化层面进行。Python 的 AST 模块可将源代码解析为 `ast.Module` 根节点下的层次结构 [30]。

Tree-sitter 是一个用于构建多语言解析器的增量式解析系统 [31]。与传统的解析器不同，Tree-sitter 具有语言无关的解析框架、增量解析能力、错误容忍机制等特点，使其特别适用于代码变更分析场景。

大语言模型（Large Language Models, LLMs）的出现为代码语义表示提供了新的技术路径 [32]。预训练代码模型（如 Codex、CodeT5、StarCoder 等）在大规模代码语料上进行预训练，学习到了代码的语义表示与生成能力 [33]。代码嵌入（Code Embedding）将代码片段映射为稠密向量表示，使得代码之间的语义相似性可通过向量距离进行度量 [34]。

然而，纯文本表示的 LLM 在处理结构化程序代码时存在固有限制。常见思路包括基于 AST 的序列化、基于图神经网络的程序图编码以及多模态信息融合等。本研究结合 Tree-sitter 的结构化解析与 LLM 的语义理解，实现从语法节点到语义推理的衔接。

2.3 多智能体系统技术

2.3.1 基于 LangGraph 的工作流建模

LangGraph 是 LangChain 生态中用于构建有状态、多角色交互应用的工作流编排框架 [35]。与传统的线性链条式（Chain）处理流程不同，LangGraph 采用图结构对复杂工作流进行建模，其中节点（Node）表示处理单元，边（Edge）表示控制流与数据流。这种图结构天然支持条件分支、循环迭代及多路径并行等复杂控制模式。

LangGraph 的核心抽象包括 StateGraph、节点（Node）和边（Edge）三个层次：状态模式常借助 Pydantic 等机制描述全局状态 [36]；节点以函数形式实现状态的读入与更新；边刻画普通迁移、条件分支及入口/终止等控制关系。框架支持惰性求值与状态持久化。

本研究采用 LangGraph 作为多智能体协同框架的核心基础设施。通过 StateGraph 定义测试生成工作流的全局状态结构，工作流中的各个处理阶段均建模为独立节点，通过边定义节点间的数据流向与控制依赖。这种基于图的工作流建模方式既保证了处理流程的清晰性，又为后续的功能扩展与优化提供了灵活性。

2.3.2 多 Agent 协同机制

多智能体系统(Multi-Agent System, MAS)是由多个具有自主能力的智能体(Agent)组成的计算系统，智能体之间通过协作完成复杂任务 [37]。与单一智能体相比，多智能体系统在问题分解、信息集成、容错冗余及并行处理等方面具有显著优势 [38]。

智能体的角色定义是多智能体系统设计的基础 [39]。每个智能体通常被赋予特定的角色，承担特定的功能职责。在软件工程应用场景中，常见的角色包括分析型 Agent（负责理解需求、分析问题）、规划型 Agent（负责制定执行计划、分解任务）、执行型 Agent（负责具体操作的实施）、验证型 Agent（负责检查结果正确性）及协调型 Agent（负责管理多个 Agent 的协作流程） [13]。

信息共享是多智能体协同的核心机制 [40]，常见模式包括点对点消息、黑板、发布-订阅与消息队列等。在基于 LLM 的系统中，常通过共享上下文或对话历史传递信息 [14]。对于可并行的子任务可并行执行，存在依赖的子任务则按拓扑顺序串行 [41]。当多个 Agent 结论不一致时，可采用权威裁定、投票、置信度比较或协商等策略 [42]。

本研究构建的多智能体测试生成系统包含 11 个专业 Agent，分别负责代码变更

解析、AST 分析、影响范围推理、测试策略规划、测试用例生成、测试执行、结果评估、缺陷模式匹配、代码检索、上下文管理和报告生成等功能。

2.4 大语言模型技术

2.4.1 代码理解与结构化生成

大语言模型在代码理解任务中的能力源于其在大规模代码语料上的预训练 [32]。预训练阶段，模型学习到编程语言的语法规则、语义模式及常见的编码范式 [43]。代码理解任务包括代码摘要、代码搜索、代码补全及代码翻译等 [18]。

代码嵌入将代码映射为稠密向量，使语义相近片段在向量空间中彼此接近 [44]。

结构化生成要求模型输出符合既定代码形态与项目规范。常见对策包括约束解码、提示工程与生成后校验等 [45-46]。本研究结合提示模板与生成后检查，以约束测试代码形态。

检索增强生成（RAG）通过从外部库检索相关片段并拼入提示，扩展模型可用知识 [47]。本研究在流水线中集成了这一机制。

2.4.2 测试用例生成与修复

基于大语言模型的测试用例生成已成为软件测试领域的研究热点 [48]。其核心难点包括：如何把变更信息组织为有效提示、如何约束输出符合工程规范、如何评价充分性等。

提示设计需要兼顾任务说明、上下文、格式约束与示例等要素 [49]；也可采用思维链/分步规划等提示策略以提升筹划性。

测试用例修复用于应对生成中的语法与语义问题 [50]，既可通过静态分析修补，也可结合执行反馈迭代。Self-healing 等研究总结了失败模式并给出自动修复策略 [51]。

充分性常用覆盖率等指标刻画；亦可通过故障注入考察检出能力。本研究以覆盖率与执行成功率为主，并在失败时进入修复回路。

综上所述，本章介绍了与本研究相关的核心技术与方法。软件测试技术为研究提供了测试理论与工程实践基础；代码变更分析技术为影响范围推理提供了技术支撑；多智能体系统技术为复杂测试生成任务的协同处理提供了架构框架；大语言模型技术为代码理解与测试用例生成提供了智能能力。这些技术与方法相互结合，共

同构成本研究的技术基础。

第3章 基于代码变更的影响分析方法

3.1 问题定义与总体架构

3.1.1 问题定义

代码变更影响分析的核心问题可形式化定义为：给定一个代码变更集合 Δ ，准确识别所有可能受该变更影响的目标程序实体集合 T ，并量化每个目标实体的受影响程度。本研究中，程序实体 T 涵盖函数（Function）、类（Class）、模块（Module）及接口（Interface）等多个粒度层次。

形式化表述如下：设程序 P 由实体集合 $E = \{e_1, e_2, \dots, e_n\}$ 组成，代码变更 Δ 包含一系列文件级别的修改 $\delta_1, \delta_2, \dots, \delta_m$ 。影响分析的输出为目标实体集合 $T \subseteq E$ ，以及每个目标实体 $t \in T$ 的影响评分 $I(t) \in [0, 1]$ ，表示该实体受到变更影响的可能性与程度。

代码变更根据其意图可分为以下三类：

- **缺陷修复型（BUG_FIX）**：旨在修复已有缺陷的代码变更，通常涉及错误处理逻辑、边界条件检查等。
- **功能新增型（FEATURE）**：旨在引入新功能的代码变更，通常涉及新增接口、扩展逻辑等。
- **重构优化型（REFACTOR）**：旨在改善代码结构或性能的代码变更，功能行为应保持不变。

传统方法主要依赖文本级 Diff 比较，仅能识别行级代码变化，难以捕获代码的真实语义变更。端到端黑箱式的影响分析方法虽然简化了处理流程，但存在可追溯性不足的问题。

3.1.2 核心理念：结构化中间表示

本研究提出基于结构化中间表示的代码变更影响分析方法，将影响分析过程分解为多个明确界定的阶段。这种方法论的优势体现在三个方面：

可追溯性（Traceability）：结构化中间表示使得分析人员能够追踪任意影响路径的完整推导过程。

可审计性 (Auditability): 每个中间表示都附带元数据（如置信度评分、来源说明、时间戳等），支持对分析过程进行事后审计。

可组合性 (Composability): 结构化中间表示支持模块化组合，不同的分析阶段可以独立开发、测试与优化。

本研究提出的结构化中间表示框架包含以下核心层次：

- **结构化变更表示 (SCR)**: 将 Unified Diff 解析为文件级、块级的结构化模型，提取程序实体与语义标签。
- **变更解构图 (CGR)**: 基于变更实体构建的有向图结构，用于表示变更符号与影响种子之间的关系。
- **语义单元表示 (SUR)**: 将变更代码与受影响代码映射为原子语义单元。
- **结构化影响报告 (SIR)**: 最终输出的结构化影响分析结果。

这四层表示形成一条完整的信息传递链条，每层都有明确的语义定义与转换接口。

3.1.3 总体架构设计

图 3-1展示了代码变更影响分析的总体架构。该架构采用基于 LangGraph 的多 Agent 工作流模式，通过共享状态（WorkflowState）在各 Agent 之间传递分析结果。




图 3-1 基于 LangGraph 多 Agent 工作流的影响分析总体架构

系统接受 Git 提交产生的 Unified Diff 格式代码变更作为输入。在 CodeChangeAgent 的 ingest_change 一步中，完成了多个核心子任务：Unified Diff 解析、符号级变更分析（change_analysis）、以及变更解构图（ChangeGraph）的构建。ingest_change 步骤的输出直接写入共享状态 WorkflowState 中，供后续 Agent 读取。

具体而言，ingest_change 的内部处理流程包含以下三个核心环节：首先通过 parse_unified_diff 解析 Diff 文本，提取变更文件列表(changed_files)和每个文件的变更块元数据(diff_hunks)；然后对每个变更文件进行符号级分析，构建 ChangeRecord 列表（change_analysis）；最后基于变更实体构建变更解构图（change_graph），建立变更符号与影响种子（impact_seeds）之间的关联。

ProjectProbeAgent 探查项目的代码结构信息，补充实体间的依赖关系上下文。ImpactAnalysisAgent 是核心影响分析模块，它读取 WorkflowState 中的 change_analysis、change_graph 等共享状态，执行语义单元建模与影响传播推理，输出包含影响图（impact_graph）、语义单元目录（semantic_units_catalog）、测试计划（impact_test_plan）和高风险项（top_risks）的结构化结果。

整个架构的核心设计原则是：各 Agent 通过 WorkflowState 共享状态进行协作，ingest_change 一步内完成多个紧密关联的子任务，后续分析模块主要读取 WorkflowState 中的共享状态而非重新计算。这种设计确保了分析过程的高效性与可追溯性。

3.2 代码变更信息提取

代码变更信息提取是影响分析的起点，其目标是将非结构化的 Unified Diff 文本转换为结构化的变更表示。

3.2.1 Unified Diff 解析与结构化

Git 生成的 Unified Diff 格式包含文件头（Hunk Header）和变更块（Hunk Body）两部分。本研究采用 Python 的 unidiff 库进行解析 [23]，并在此基础上设计了结构化的解析结果格式。

parse_unified_diff 函数返回的解析结果是一个字典结构，包含三个核心字段：

- **changed_files**: 变更文件路径列表 (List[str])，按变更顺序排列。
- **hunks_by_file**: 变更块元数据字典 (Dict[str, List[HunkMeta]])，键为文件路径，值为该文件的变更块元数据列表。

- **stats**: 变更统计信息，包含总文件数、总新增行数、总删除行数等。

每个变更块元数据（HunkMeta）的结构定义如下：

```
1 HunkMeta = {
2     "source_start": int,      # 源文件起始行号
3     "source_length": int,    # 源文件块长度
4     "target_start": int,     # 目标文件起始行号
5     "target_length": int,    # 目标文件块长度
6     "added": int,            # 新增行数
7     "removed": int           # 删除行数
8 }
```

解析流程包含以下关键步骤：**Diff 文本标准化**（统一换行符格式、处理编码问题、过滤二进制文件差异）、**变更块提取**（识别文件头标记与变更块标记）、**行级内容解析**（统计新增、删除、上下文行数）、**结构化输出**（封装为统一的数据接口）。

解析完成后，系统输出变更文件列表与每个文件的变更块元数据。这些结构化数据作为后续 **AST 分析与实体抽取** 的输入。行级详细信息在解析阶段使用后，主要以统计形式（如 **added/removed** 计数）参与后续处理，不需要全程保留为独立的行级变更数据结构。

3.2.2 变更文件与代码块建模

在文件级变更信息的基础上，本研究构建了双层的变更模型作为概念框架：

文件级变更模型描述了变更文件的整体信息，包括文件路径、变更类型及变更统计。文件级模型提供了最粗粒度的变更概览，适用于确定需要重点关注的变更文件集合。

块级变更模型描述了单个变更块的详细信息，包括块在文件中的位置、涉及的函数或类（通过上下文行推断）、以及块内变更的类型分布（通过 **added/removed** 计数反映）。

作为概念框架，三层模型（文件 → 块 → 行）的层级关系可形式化表示为：

$$\Delta_{file} = \{f_1, f_2, \dots, f_n\}$$

$$\Delta_{hunk}(f_i) = \{h_1, h_2, \dots, h_m\}$$

行级信息 $\Delta_{line}(h_j)$ 在解析阶段用于计算统计指标，但不作为独立数据结构在后续模块间传递。

这种设计在保持模型完整性的同时，避免了行级数据的冗余存储与传递开销，使系统能够高效处理大规模变更场景。

3.2.3 变更实体抽取与符号级分析

文本级的变更解析无法直接回答“哪些函数或类发生了变更”这一关键问题。为获取变更实体的语义信息，需要对变更代码进行 AST 解析 [29]，并结合 Unified Diff 上下文推断变更实体的符号级信息。

变更实体抽取的过程分为两步：上下文恢复与 AST 解析。上下文恢复是指根据 Diff 中的上下文行信息，从工作区文件恢复变更代码块的完整函数或类定义。上下文范围的确定遵循以下启发式规则：

1. 从变更块所在行向上遍历，寻找最近的函数或类定义的起始位置。
2. 从变更块所在行向下遍历，寻找函数或类定义结束的标记。
3. 对于 Python 代码，利用缩进层级判断函数边界的结束位置。

恢复后的完整代码片段传入 AST 解析器进行处理。本研究集成 Tree-sitter 作为多语言通用解析引擎 [31]，其优势体现在多语言支持、增量解析与容错能力等方面。针对不同编程语言，本研究实现了相应的解析适配：

- **Python**：使用 Python 标准库中的 ast 模块进行语法树解析 [30]。
- **Java、C++、JavaScript/TypeScript**：使用 Tree-sitter 进行解析，支持类声明、方法声明、函数定义等实体识别。

需要说明的是，上述上下文恢复规则是针对 Python 语言的启发式实现。对于其他编程语言，上下文边界判断规则可能有所不同。Tree-sitter 的多语言支持为未来扩展提供了灵活性。

AST 解析后，通过遍历语法树节点提取关键实体信息。抽取结果封装为变更记录对象（ChangeRecord），结构定义如下：

```
1 ChangeRecord = {
2     "entity": str,          # 实体名称
3     "type": str,            # 实体类型: function/class/method
4     "change_type": str,     # 变更类型: ADD/MODIFY/DELETE
5     "semantic_tags": List[str], # 语义标签列表
6     "test_focus": List[str], # 测试关注点列表
7     "intent": str,          # 变更意图: BUG_FIX/FEATURE/REFACTOR
8     "impact_seeds": List[ImpactSeed] # 影响种子列表
9 }
10
11 ImpactSeed = {
12     "kind": str,            # 种子类型: function/class/variable
13     "name": str,           # 种子名称
14     "source": str          # 种子来源: diff/ast/manual
15 }
```

语义标签（semantic_tags）是变更实体的重要属性，用于描述代码变更的语义特征。本研究定义的语义标签集合包括：

- api_signature_changed: API 签名变更，函数参数或返回值类型发生变化。
- dependency_call_changed: 依赖调用变更，函数内部调用的外部依赖发生变化。
- exception_handling_changed: 异常处理变更，异常捕获或抛出逻辑发生变化。
- logic_branch_changed: 逻辑分支变更，条件判断或分支逻辑发生变化。
- null_check_added: 空值检查新增，新增了空值判断逻辑。
- return_value_changed: 返回值变更，函数返回值的结构或类型发生变化。
- input_validation_added: 输入校验新增，新增了参数校验逻辑。

变更实体抽取完成后，系统输出变更文件摘要列表，每个文件摘要（FileChange-Summary）包含文件路径与该文件的变更记录列表。这些结构化数据作为 Change Graph 构建模块与后续影响分析模块的关键输入。

3.3 变更解构图构建

变更解构图（Change Graph）是用于表示代码变更实体之间关联关系的数据结构，用于支持语义单元建模与影响传播分析。

3.3.1 节点与边的定义

Change Graph 采用有向图结构，其节点和边的定义如下：

节点类型（kind）包括：

- **file**：表示源代码文件节点，ID 为文件路径。
- **symbol**：表示程序符号（函数、类、方法）节点，ID 格式为”文件路径:type: 实体名”。
- **seed**：表示影响种子节点，用于追踪影响传播路径。
- **focus**：表示测试关注点节点，与符号节点关联。

边类型（relation）包括：

- **contains_change**：文件节点指向符号节点，表示该符号在文件中发生了变更。
- **emits_seed**：符号节点指向 seed 节点，表示该符号产生的影响种子。
- **test_focus**：符号节点指向 focus 节点，表示该符号关联的测试关注点。

节点与边的权重(weight)反映关联的紧密程度,范围为 [0, 1]。例如, **contains_change** 边的权重通常设为 1.0, 表示直接变更关系; **emits_seed** 边的权重设为 0.85, 表示符号对种子的发射强度。

3.3.2 变更解构图构建方法

Change Graph 的构建在 ingest_change 步骤中完成，具体算法如下：

变更解构图不实现遍历全仓库的依赖分析，而是聚焦于从变更实体直接衍生的关联关系。这种轻量级的图结构支持种子驱动的启发式影响传播，避免了构建完整代码依赖图的高昂开销。

3.4 语义单元建模方法

语义单元是影响分析中的关键概念，代表代码变更的原子语义功能块。本节详细阐述语义单元的定义、分类体系与提取方法。

算法 1 变更解构图构建算法

输入： 变更文件摘要列表 $change_analysis$

输出： Change Graph G_{change}

```
1:  $G \leftarrow$  创建空的有向图
2:  $nodes \leftarrow$  初始化节点集合
3:  $edges \leftarrow$  初始化边集合
4: for  $file\_summary$  in  $change\_analysis$  do
5:    $file\_node \leftarrow$  创建节点 ( $file, file\_summary.file$ )
6:    $nodes.add(file\_node)$ 
7:   for  $change$  in  $file\_summary.changes$  do
8:      $sym\_id \leftarrow f"file\_summary.file : change.type : change.entity"$ 
9:      $sym\_node \leftarrow$  创建节点 ( $symbol, sym\_id$ )
10:     $sym\_node.meta \leftarrow$  填充变更元信息
11:     $nodes.add(sym\_node)$ 
12:     $edges.add(contains\_change(file\_node, sym\_node, 1.0))$ 
13:    for  $seed$  in  $change.impact\_seeds$  do
14:       $seed\_id \leftarrow f"seed : sym\_id"$ 
15:       $seed\_node \leftarrow$  创建节点 ( $seed, seed\_id$ )
16:       $seed\_node.meta \leftarrow$  填充种子信息
17:       $nodes.add(seed\_node)$ 
18:       $edges.add(emits\_seed(sym\_node, seed\_node, 0.85))$ 
19:    end for
20:  end for
21: end for
22:  $G.nodes \leftarrow nodes$ 
23:  $G.edges \leftarrow edges$ 
24: return  $G_{change}$ 
```

3.4.1 原子语义单元定义

原子语义单元（ASU）是指在语义层面不可再分的代码功能块。ASU 的划分遵循功能单一性、边界清晰性、可测试性等原则。

基于语义特征，ASU 分为以下四种类型：

- **配置型（config）**：配置项的读取与管理，如环境变量、配置文件等。
- **异常处理型（exception）**：异常捕获、抛出与处理逻辑。
- **API 型（api）**：暴露给外部调用的接口函数，涉及网络请求、客户端调用等。
- **数据处理型（data_processing）**：数据的转换、过滤、聚合等操作。

ASU 的形式化定义如下：

$$ASU = (id, type, risk_score, priority_score, call_chain, downstream, upstream, edge_types)$$

其中，各字段的含义为：

- *id*：语义单元的唯一标识符，格式为“*type : slug*”，如“api:request”。
- *type* $\in \{config, exception, api, data_processing\}$ ：语义单元类型。
- *risk_score* $\in [0.14, 0.89]$ ：风险评分，反映变更的内在风险。
- *priority_score* $\in [0.2, 0.9]$ ：优先级评分，归一化后的综合影响程度。
- *call_chain*：调用链列表，包含符号标识符。
- *downstream*：下游符号列表，通过 *seed* 关联追踪到的受影响符号。
- *upstream*：上游符号列表，当前符号被哪些符号调用。
- *edge_types*：边类型标签集合，如“config”、“call”、“data”等。

语义单元的优先级划分（P0/P1/P2）规则如下：

- **P0（高优先级）**：config、exception、api 类型的语义单元，默认最高优先级。

- **P1（中优先级）**: `data_processing` 类型且 $priority_score \geq 0.52$ 的语义单元。
- **P2（低优先级）**: 其余 `data_processing` 类型的语义单元。

3.4.2 语义标签体系

语义标签 (`semantic_tags`) 是变更实体的重要属性, 用于描述代码变更的语义特征。本研究定义的语义标签集合如前述 `ChangeRecord` 定义所示。

语义标签在语义单元提取过程中起关键作用: 从 `ChangeRecord` 的 `impact_seeds` 和 `semantic_tags` 出发, 通过规则映射推断语义单元类型。例如, `api_signature_changed` 和 `dependency_call_changed` 标签映射为 `api` 类型, `input_validation_added`、`null_check_added`、`exception_handling_changed` 映射为 `exception` 类型, `logic_branch_changed`、`return_value_changed` 映射为 `data_processing` 类型。

每个语义单元类型还关联一组测试关注点 (`test_focus`), 通过规则派生:

- **config**: `env_missing` (环境变量缺失)、`fallback` (配置回退)。
- **exception**: `error_paths` (错误分支)、`exception_assertion` (异常断言)。
- **api**: `retry` (重试)、`timeout` (超时)、`mock` (Mock 策略)。
- **data_processing**: `boundary` (边界值)、`invalid_input` (非法输入)。

3.4.3 语义单元提取方法

语义单元的提取以规则驱动为主, 以大语言模型推断为可选增强。

规则驱动的提取是主路径: 语义单元主要从 `ChangeRecord` 的 `impact_seeds` 与 `semantic_tags` 聚合而来。具体过程如下:

1. 对每个 `ChangeRecord`, 遍历其 `impact_seeds` 列表, 根据 `seed` 的名称和 `kind` 推断语义单元类型 (通过正则匹配与关键词分析)。
2. 对每条 `semantic_tag`, 映射其对应的语义单元类型。
3. 聚合相同类型的语义单元, 按原子粒度 (每条 `seed` 或每条 `tag` 对应一个语义单元) 构建语义单元候选。
4. 对候选进行去重与合并, 按语义单元 ID 聚合来自不同符号的相同语义能力。

LLM 推断是条件触发的可选增强：在默认配置下 (`used_llm: False`)，系统使用纯规则驱动的方法生成语义标签。LLM 推断仅在环境变量 `MUTIAGENT_IMPACT_LLM_REFINE` 启用时触发，用于对语义标签进行精细化调整。这种设计确保了主流场景下的分析效率，同时保留了语义增强的可能性。

语义单元提取与归类的完整流程如下：

1. 从 `WorkflowState` 获取 `change_analysis`（变更文件摘要列表）。
2. 对每个变更记录，执行原子行提取 (`_atomic_rows_for_change`)。
3. 对语义单元候选执行基于规则的类型推断与合并。
4. 构建语义单元目录 (`semantic_units_catalog`)，计算优先级评分。
5. 关联测试策略 (`test_strategy`) 与测试关注点 (`test_focus`)。

该流程确保了语义单元信息的完整性与准确性，为测试导向分析提供了可靠的基础。

3.5 影响传播与风险评估模型

影响传播是变更影响分析的核心环节，目标是基于种子驱动的启发式关联追踪变更的影响范围，并量化每个受影响实体的风险程度。

3.5.1 基于种子与标签的传播机制

本研究采用 `seed/tag` 驱动的启发式关联方法进行影响传播，而非构建全仓库的依赖图。

传播机制的核心思想是：当某个符号发生变更时，其 `impact_seeds` 中的函数名、类名等信息可以作为影响追踪的种子，在其他符号的变更记录中寻找同名或相关的实体。

具体传播过程如下：

1. 构建种子名称索引 (`_seed_occurrence_index`): 遍历所有变更记录的 `impact_seeds`，建立种子名称（去噪后）到 (文件路径, 符号 ID) 的映射。
2. 对每个语义单元，解析其关联符号的 `seed` 名称。

3. 在索引中查找同名 `seed` 的其他出现位置，建立跨符号关联。
4. 按关联强度（优先同文件，其次跨文件）保留最多 5 个下游符号。

传播深度 (`propagation_depth`) 的计算遵循以下规则：从直接变更的符号出发，按传播跳数递增，每经过一跳传播深度加 1。系统默认的最大传播深度 (D_{max}) 通过环境变量 `MUTAGENT_IMPACT_MAX_PROPAGATION_HOPS` 配置，默认为 3 跳。

这种 `seed/tag` 驱动的启发式传播避免了构建完整调用图的复杂性，同时能够有效追踪变更的实际影响范围。

3.5.2 风险评分与优先级量化

本研究的风险评分模型综合考虑变更意图、语义类型、传播深度、符号引用数等多维因素。

风险评分 (`risk_score`) 的计算公式为：

$$risk = change_weight(intent) \times decay^{depth} \times semantic_weight(type) \times tag_risk(tags)$$

其中：

- $change_weight(intent)$ ：变更意图权重，`BUG_FIX` 为 1.0，`FEATURE` 为 0.74，`REFACTOR` 为 0.58。
- $decay = 0.88^{\max(0, depth)}$ ：基于传播深度的指数衰减因子。
- $semantic_weight(type)$ ：语义类型权重，`config` 为 1.1，`exception` 为 1.14，`api` 为 1.02，`data_processing` 为 0.76。
- $tag_risk(tags)$ ：语义标签微调因子，根据是否包含 `null_check_added`、`input_validation_added`、`exception_handling_changed`、`logic_branch_changed`、`api_signature_changed` 等标签进行累乘（上限 1.12）。

优先级评分 (`priority_score`) 的计算公式为：

$$raw_priority = risk \times change_mult \times centrality_mult \times \log(1 + refs) \times integration_mult$$

$$priority = normalize(raw_priority, [0.2, 0.9])$$

其中：

- *change_mult*: 变更倍数，直接变更的符号为 1.5，传播影响的符号为 1.0。
- *centrality_mult*: 中心性乘子，根据下游符号数量与调用链长度计算(0.8/1.0/1.2 三档)。
- *refs*: 引用符号数量（同一语义单元关联的符号数）。
- *integration_mult*: 集成风险乘子，跨文件关联时为 1.3，否则为 1.0。
- *normalize*: 将 *raw_priority* 归一化到 [0.2, 0.9] 区间。

基于 *priority_score*，受影响语义单元可划分为以下优先级层次：

- **P0（高风险）**: *config*、*exception*、*api* 类型的语义单元，需要优先测试。
- **P1（中风险）**: *data_processing* 类型且 *priority_score* ≥ 0.52 的语义单元，需要测试。
- **P2（低风险）**: 其余语义单元，可选择性测试。

3.6 影响分析结果生成与结构化输出

影响分析完成后，需要将分析结果组织为结构化的输出格式，供下游模块使用。

3.6.1 结构化输出设计

本研究设计了 JSON 格式的结构化输出，涵盖影响分析的主要结果与元信息。输出文件保存为 *impact_result.json*，包含以下核心字段：

- **impact_graph**: 影响图结构，列表形式，每个元素包含 *file* 路径与关联的 *symbols*。
- **semantic_units_catalog**: 语义单元目录，包含所有原子语义单元及其属性。

- **impact_test_plan**: 影响测试计划，按符号组织的测试建议。
- **top_risks**: 高风险项列表，按 **priority_score** 排序的前 N 项。
- **debug**: 调试信息，包含分析模式、统计指标等。

语义单元目录（**semantic_units_catalog**）中每个元素的结构定义如下：

```
1 SemanticUnit = {
2     "semantic_unit_id": str,          # 唯一标识符
3     "type": str,                     # 语义类型
4     "source": str,                   # 来源（seed或semantic_tag）
5     "risk_score": float,             # 风险评分
6     "priority_score": float,         # 优先级评分
7     "test_priority": str,            # 测试优先级 P0/P1/P2
8     "centrality_factor": float,     # 中心性因子
9     "call_chain": List[str],         # 调用链
10    "downstream": List[str],          # 下游符号
11    "upstream": List[str],            # 上游符号
12    "edge_types": List[str],          # 边类型标签
13    "integration_risk": bool,         # 集成风险标志
14    "referenced_symbol_ids": List[str], # 引用的符号列表
15    "propagation_depth": int,         # 传播深度
16    "test_focus": List[dict],         # 测试关注点
17    "test_strategy": List[dict]       # 测试策略
18 }
```

影响图（**impact_graph**）的结构定义如下：

```
1 ImpactGraphFile = {
2     "file": str,                     # 文件路径
3     "symbols": List[ImpactGraphSymbol]
4 }
5
6 ImpactGraphSymbol = {
7     "name": str,                     # 符号名称
8     "entity_type": str,              # 实体类型
9     "symbol_id": str,                # 符号标识符
10    "semantic_unit_ids": List[str],   # 关联的语义单元
11    "centrality": float               # 中心性评分
12 }
```

3.6.2 与下游模块的接口规范

影响分析结果通过 WorkflowState 传递给下游 Agent 模块：

- **测试规划 Agent** 读取 impact_test_plan 获取按优先级排序的测试建议。
- **检索 Agent** 读取 semantic_units_catalog 进行相似用例检索。
- **测试生成 Agent** 读取 semantic_units_catalog 获取语义单元的完整信息。

结构化的输出设计确保了模块间的松耦合与独立演进能力。

第 4 章 多智能体测试生成系统设计与实现

4.1 系统总体架构设计

本章围绕“面向代码变更的多智能体回归测试用例生成”这一核心任务，阐述原型系统的总体架构设计。

4.1.1 系统总体架构

本系统采用四层架构模型（见图 4-1），自顶向下依次为：接入与展示层、编排与状态层、智能体执行层、运行与评估支撑层。该分层设计遵循关注点分离原则，使得各层职责明确、接口清晰，便于独立演进与测试。

接入与展示层基于 FastAPI 框架构建，负责接收外部请求并返回处理结果。该层对外暴露统一的 RESTful API 接口，支持同步调用与流式响应两种模式。请求与响应的数据模型均采用 Pydantic 进行定义与校验。

编排与状态层采用 LangGraph 的 StateGraph 机制实现，负责定义多智能体之间的工作流拓扑与状态传递逻辑。StateGraph 维护一个贯穿整个工作流的全局状态对象 WorkflowState，承载从原始 diff 到最终评估结果的完整数据。

智能体执行层包含 12 个命名节点，按照流水线拓扑顺序依次执行。各智能体均为独立执行单元，多数节点以 LLM 为可选增强（如 ImpactAnalysisAgent 默认不启用 LLM，CodeChangeAgent 以 Tree-sitter/启发式为主、LLM 仅在 refine/guess 阶段条件调用），或与静态分析/执行逻辑组合（如 ExecutionAgent、EvaluationAgent 不调用 LLM），智能体之间不直接通信，而是通过读写共享状态实现协作。

运行与评估支撑层提供测试执行、覆盖率采集与结果评估的能力。该层封装了 pytest 的调用接口，支持在工作树隔离环境中执行生成的测试用例，并采集行覆盖率等基础指标。

在技术选型上，大模型调用层采用 OpenAI 兼容客户端设计，支持 DeepSeek、智谱等主流模型的灵活切换；状态管理层基于 Pydantic 模型实现数据结构定义与运行时校验；持久化层采用 SQLite 记录工作流执行轨迹。

与单智能体方案相比，本系统的架构设计具有以下差异特征：采用流水线分工模式，降低了单个智能体的认知负荷；所有中间表示均显式存储于全局状态中，可




图 4-1 系统四层架构示意图

供后续审计与消融实验使用；关键能力以可配置开关的形式嵌入状态对象。

4.1.2 多智能体协同流程

完整的工作流节点序列为：CodeChangeAgent → ProjectProbeAgent → ImpactAnalysisAgent → BugPatternAgent → TestPlanningAgent → TestPrioritizationAgent → RetrievalAgent → TestGenAgent → TestRepairAgent → ExecutionAgent → EvaluationAgent → FeedbackAgent → END。

各智能体的职责划分如下：

- CodeChangeAgent：负责解析原始 diff 并构建变更理解结构
- ProjectProbeAgent：提取项目结构与依赖信息
- ImpactAnalysisAgent：分析代码变更的影响范围，生成影响图
- BugPatternAgent：识别潜在缺陷模式
- TestPlanningAgent：基于影响分析结果生成结构化测试计划
- TestPrioritizationAgent：对测试用例进行优先级排序

- **RetrievalAgent**: 检索相似测试作为生成参考
- **TestGenAgent**: 核心生成单元，负责产出 `pytest` 测试代码
- **TestRepairAgent**: 对生成的测试进行修复与优化
- **ExecutionAgent**: 在隔离环境中执行测试并采集结果
- **EvaluationAgent**: 汇总评估指标
- **FeedbackAgent**: 生成最终报告并更新全局状态

数据在各节点之间的传递通过 `WorkflowState` 实现。以变更理解阶段为例：`CodeChangeAgent` 读取原始 `diff`，输出变更图与变更分析字段并写入状态；`ImpactAnalysisAgent` 再读取上述字段，在影响分析后将影响图与语义单元目录写入状态；后续节点依次读取并丰富相关字段，形成端到端的数据流闭环。

系统定义了三种核心的中间表示数据结构：变更图（`ChangeGraph`）的节点类型包含文件节点（`file`）、符号节点（`symbol`）、种子节点（`seed`）和测试关注点节点（`focus`）四类；影响图（`impact_graph`）按分层组织方式组织影响范围；语义单元目录（`SemanticUnit Catalog`）将代码实体按类型划分为 `config`、`exception`、`api`、`data_processing` 等类别，每个单元包含优先级评分。

结构化测试用例（`StructuredTestCase`）作为影响侧与生成侧之间的桥梁，其字段设计包含 `symbol_id`、`semantic_unit_ids` 等影响侧标识，以及 `scenario`、`input`、`mock`、`assertions` 等生成侧约束字段。如图 4-2 所示，`StructuredTestCase` 的核心字段包括用例标识符、目标符号、测试分层、优先级、结构化输入（`scenario`）、Mock 说明（`mock`）、断言列表（`assertions`）和语义单元列表等组成部分。

4.1.3 质量门控机制

为确保生成的回归测试用例具备基本的可用性与有效性，本系统在流水线中嵌入多阶段质量门控机制，覆盖语法校验、静态修复、执行验证与量化评估等环节。

语法正确性检查采用两阶段门控机制。**第一阶段**位于 `TestGenAgent` 生成测试之后，系统使用 Python 的 `compile` 函数（`mode='exec'`）对生成的代码进行语法校验（`exec_syntax_error`），若解析失败则记录错误信息并可触发 LLM 重试；**第二阶段**位于 `TestRepairAgent` 执行之前及过程中，再次对已生成的测试文件进行语法检查，若




图 4-2 结构化测试用例模型

规则修复无法解决问题则调用 LLM 生成修复后的代码。`TestRepairAgent` 专门负责处理静态层面与执行前可侦测的问题，其修复范围包括：语法错误修正、导入语句补全、`fixture` 依赖消解、以及代码风格规范化。

执行结果质量评估由 `EvaluationAgent` 完成，计算以下核心指标：通过率、变更行覆盖率、测试选择精准度（F1 分数）；变更函数覆盖率为实验扩展指标（记录于 `experiment` 相关报告中）。

表 4-1 质量门控指标体系

指标类别	指标名称	计算方式	阈值说明
语法质量	AST 解析通过率	成功解析数 / 总生成数	≥ 95%
执行质量	用例通过率	通过用例数 / 总用例数	≥ 80%
覆盖率	变更行覆盖率	覆盖变更行 / 总变更行	≥ 70%
覆盖率	变更函数覆盖率	覆盖函数数 / 总函数数	≥ 80%
精准度	Selection F1	$2 \times P \times R / (P + R)$	≥ 0.75

注：上表所示阈值为实验口径/人工评审参考标准，非代码内硬编码门控开关。

为支持消融实验与方案对比，系统定义了多个可配置开关字段，包括 `retrieval_enabled`、

`bug_pattern_enabled`、`test_repair_enabled`、`feedback_enabled`、`impact_analysis_enabled` 等。这些开关的默认值由环境变量（如 `MUTIAGENT_ENABLE_*` 系列）给出，可在请求体中覆盖，以实现灵活的实验控制。

4.2 核心 Agent 模块设计

本系统采用流水线架构，将回归测试生成任务分解为多个阶段，通过 12 个 Agent 节点实现各阶段功能。各 Agent 通过读写共享的 `WorkflowState` 进行状态传递与协作。

4.2.1 变更理解阶段

变更理解阶段是整个流水线的入口，负责解析代码变更并构建结构化的变更表示。

4.2.1.1 CodeChangeAgent（变更理解）

`CodeChangeAgent` 作为流水线的首个 Agent，承担着解析代码变更并建立变更语义模型的任务。其核心入口函数为 `ingest_change`。

该 Agent 的核心处理流程分为四个主要步骤：

1. `parse_unified_diff` 函数负责解析统一的 `diff` 格式，提取变更文件列表和变更块
2. `check_diff_worktree_consistency` 函数验证解析得到的 `diff` 与工作树状态的一致性
3. `_build_change_analysis` 方法构建变更分析结果
4. `build_change_graph` 方法将分析结果转化为结构化的变更图

该 Agent 的输入状态字段为 `repo_path` 和 `diff`，输出状态字段包括 `changed_files`、`diff_hunks`、`change_analysis` 和 `change_graph`。

`CodeChangeAgent` 的关键设计在于变更图的数据结构设计。变更图的节点类型包含文件节点、符号节点、种子节点和测试关注点节点四类，边上携带权重与关系类型标签。

4.2.1.2 ProjectProbeAgent（项目探测）

ProjectProbeAgent 负责探测代码仓库的技术栈信息，为后续测试生成提供必要的环境配置依据。其核心流程以 `_build_profile` 方法为主导，探测并推断项目的编程语言、框架类型、模块根路径、依赖声明行，形成完整的项目画像。

该 Agent 读取 CodeChangeAgent 输出的 `changed_files` 字段，用于依赖推断和符号采集。写出的状态包括 `project_profile`（项目技术栈画像）。虚拟环境相关的预检信息（如 `ensure_dataset_venv` 的调试输出）记录在 `debug.env_bootstrap` 字段中，供后续 Agent 在需要时参考，但不作为 `project_profile` 的主字段。

4.2.1.3 ImpactAnalysisAgent（影响分析）

ImpactAnalysisAgent 负责分析代码变更的影响范围，识别需要重点测试的语义单元。其处理流程首先调用 `build_impact_graph` 方法构建影响图。最终输出影响图和语义单元目录。

语义单元目录的类型分类体系 (SemanticUnitType) 包含四类：`config`（配置项与参数变更）、`exception`（异常处理逻辑变更）、`api`（接口签名与行为变更）、`data_processing`（数据处理与转换逻辑变更）。其中 `integration_risk` 是一个布尔属性字段，表示该语义单元是否存在集成风险，而非独立的类型枚举值。

该 Agent 的关键设计体现在语义单元的 `priority_score` 由风险系数、变更权重、中心性指标、引用频次和集成风险五个维度综合计算得出。

4.2.2 测试规划阶段

测试规划阶段基于变更理解的结果，制定测试策略与优先级。

4.2.2.1 BugPatternAgent（缺陷模式识别）

BugPatternAgent 负责识别代码变更可能引入的典型缺陷模式，为测试用例设计提供针对性指导。该 Agent 利用语义单元目录和风险排序列表构建查询签名，采用基于词频的稀疏向量表示与相似度计算方法寻找匹配的缺陷模式案例。

该 Agent 的检索机制使用 `_make_embedding` 方法生成 token 频次稀疏向量，通过余弦相似度检索历史案例。内置的规则模板按语义单元类型映射回归模式名称，包括：`config` 类型映射到 `configuration_drift_or_fallback_regression`；`exception` 类型映射到 `error_handling_regression`；`api` 类型映射到 `api_contract_or_integration_regression`；

`data_processing` 类型映射到 `data_transformation_regression`。

若 `BugPatternAgent` 启用且 LLM 可用，则调用 `_llm_refine_patterns` 进行模式精炼；若 LLM 不可用，则仅使用规则候选结果作为输出。这种设计确保了系统在无 LLM 环境下仍能提供基础的缺陷模式指导。

4.2.2.2 TestPlanningAgent（测试规划）

`TestPlanningAgent` 负责将影响分析结果转化为结构化的测试计划，是测试生成的核心依据。

该 Agent 的处理流程设计为幂等操作：若测试计划已存在则直接跳过。具体流程首先调用 `generate_test_cases` 方法生成结构化的测试用例列表。每个 `StructuredTestCase` 包含场景描述、测试目标、所需语义单元标识等信息。Agent 随后执行去重操作并确保 P0 用例覆盖率，调用 `_ensure_p0_coverage` 方法补充必要的测试用例。最终通过 `_cap_cases` 方法限制用例数量上限，并生成 `StructuredTestPlanRoot` 结构化根节点。

算法 2 TestPlanningAgent 测试规划生成（抽象示意）

```

1: Procedure plan_tests(state)
2: if state.test_plan  $\neq \emptyset$  then
3:   return state
4: end if
5: cases  $\leftarrow$  generate_test_cases(state.impact_test_plan, state.semantic_units_catalog)
6: cases  $\leftarrow$  deduplicate(cases)
7: cases  $\leftarrow$  ensure_p0_coverage(cases)
8: root  $\leftarrow$  StructuredTestPlanRoot(cases)
9: root  $\leftarrow$  cap_cases(root, MAX_CASES)
10: state.structured_test_plan  $\leftarrow$  root
11: state.test_plan  $\leftarrow$  plan_items_from_cases(root.test_cases)
12: return state

```

4.2.2.3 TestPrioritizationAgent（测试优先级）

`TestPrioritizationAgent` 负责对生成的测试计划进行优先级排序，指导测试资源的高效分配。

该 Agent 的核心评分逻辑以影响图符号中心性（`sym centrality`）为主因子：对于每个测试用例关联的符号及其对应的语义单元，计算其 `priority_score` 的最大值，再乘以该符号在影响图中的 `centrality` 得分。同时，当存在优先级相等的候选用例时，

Agent 借助变更图进行加权 tie-break 分析 ($\times 0.15$ 权重)，选择与核心变更更紧密关联的测试用例。

最终生成的测试用例携带优先级标签 (high/medium/low)，该优先级由阈值 0.72 和 0.42 划分。需要注意的是，此处的 high/medium/low 与影响侧 StructuredTest-Case.priority (P0/P1/P2，由语义单元类型规则定义) 属于不同的分层体系，前者用于测试执行排序，后者用于影响分析标记。

优先级分档策略是该 Agent 的关键设计。high 档用例要求优先执行；medium 档用例在资源允许时执行；low 档用例可延后或抽样执行。

4.2.3 测试生成阶段

测试生成阶段是流水线的核心环节，负责基于测试计划和变更上下文生成可执行的测试代码。

4.2.3.1 RetrievalAgent (上下文检索)

RetrievalAgent 负责从代码仓库中检索与变更相关的上下文信息，为测试生成提供项目背景知识。

该 Agent 的处理流程首先从变更路径、测试计划等来源抽取关键词序列。Agent 扫描代码仓库收集候选的 Python 源文件和测试文件集合，采用基于词命中的评分机制计算每个片段与查询关键词的相关度，选取 Top-N 得分最高的片段组成检索结果。

4.2.3.2 TestGenAgent (测试生成)

TestGenAgent 是流水线的核心生成 Agent，负责基于结构化测试计划和变更上下文生成可执行的测试代码。

当大语言模型可用时，Agent 调用 `_llm_generate` 方法构造包含项目画像、结构化测试计划、diff 上下文和检索片段的 Prompt，发送给 LLM 生成测试代码。生成的主文件为 `tests/test_generated_regression.py`。生成的测试代码随后经过一系列清洗处理，包括去除多余解释文本、修正 import 错误、规范函数命名等 (`sanitize_*` 链)。Agent 执行语法检查 (`compile` 函数，`mode='exec'`)，若失败则进行 LLM 重试；若重试仍失败但需保证测试文件存在，则可能生成占位用例。

Prompt 工程是该 Agent 的核心技术要点。高质量的 Prompt 需要综合项目画像提供领域背景、结构化测试计划明确测试意图、diff 上下文呈现具体变更、检索片段补

算法 3 TestGenAgent 测试生成流程（抽象示意）

```

1: Procedure generate_tests(state)
2: prompt  $\leftarrow$  _llm_generate(project_profile, structured_test_plan, change_analysis,
    diff_hunks, retrieved_context)
3: raw  $\leftarrow$  call_llm(prompt)
4: clean  $\leftarrow$  _sanitize_comments(raw)
5: clean  $\leftarrow$  _sanitize_imports(clean)
6: clean  $\leftarrow$  _sanitize_naming(clean)
7: if compile(clean, mode = 'exec') failed then
8:   clean  $\leftarrow$  retry_with_llm(clean)
9:   if compile(clean) still failed then
10:    clean  $\leftarrow$  placeholder_test()
11:   end if
12: end if
13: state.generated_tests  $\leftarrow$  {GeneratedTestFile(clean, path =
    tests/test_generated_regression.py')}
14: return state

```

充项目规范。

4.2.4 测试修复阶段

测试修复阶段位于测试生成与测试执行之间，负责修复生成的测试代码中的语法和导入问题。

4.2.4.1 TestRepairAgent（测试修复）

TestRepairAgent 负责在测试执行前修复生成的测试代码中的语法和导入错误。

该 Agent 的处理流程以单个 GeneratedTestFile 为处理单元。对于每个测试文件，Agent 首先执行 exec_syntax_error 检查，验证代码的可解析性。若语法检查失败，Agent 首先尝试基于规则的修复策略，包括修正 import 路径、补充缺失导入、修复语法结构等。当规则修复无法解决问题时，Agent 可选调用 LLM 生成修复后的代码。

TestRepairAgent 的设计以可运行性与导入/语法修复为主目标，不设专门改断言的目标。修复后的代码内容更新至对应文件的 content 字段。

4.2.4.2 ExecutionAgent（测试执行）

ExecutionAgent 负责在正确配置的虚拟环境中执行测试用例，并收集结构化的执行结果。

该 Agent 的核心处理流程首先确定 Python 解释器路径。Agent 在 .mutiagent/reports/ 目录下创建以时间戳命名的报告目录。测试执行通过子进程调用 pytest 完成，可选启

用代码覆盖率采集功能。执行完成后，Agent 解析生成的 JUnit XML 文件，提取测试结果摘要。

4.2.5 评估反馈阶段

评估反馈阶段负责评估测试执行结果的质量，并生成改进建议。

4.2.5.1 EvaluationAgent（结果评估）

EvaluationAgent 负责对测试执行结果进行全面评估，计算变更覆盖率和各项质量指标。

该 Agent 的处理流程首先读取执行信息。Agent 解析 coverage.json 文件获取代码覆盖率数据，计算变更行的覆盖率 recall。最终，Agent 计算所有评估指标，输出至状态对象。

表 4-2 评估指标体系

指标名称	符号	描述说明
变更行覆盖率	C_{line}	diff 增加行中被测试执行的比例
新增函数覆盖率	C_{func}	变更涉及的新增函数被测试覆盖的比例
跨模块测试数	N_{cross}	实验统计指标：测试用例涉及多个模块的数量
遗漏变更点数	N_{miss}	实验统计指标：高风险语义单元未被测试覆盖的数量

注： N_{cross} 和 N_{miss} 为实验统计指标，由外部脚本计算得出，非 EvaluationAgent 固定输出。

4.2.5.2 FeedbackAgent（反馈优化）

FeedbackAgent 负责基于评估结果生成针对性的改进建议，完成流水线的反馈闭环。

该 Agent 仅在 run_eval 模式且存在 evaluation 结果时触发。处理流程首先计算质量指标。当测试全部通过时，Agent 区分正常的通过和降级通过 (degraded_pass)，后者表示测试虽然通过但某些质量指标出现下降。当存在测试失败时，Agent 基于失败模板生成初步建议，必要时调用 LLM 生成更具针对性的改进建议。当 LLM 可用时，Agent 会生成 chat_text 字段汇总分析结果。

FeedbackAgent 的设计遵循”只读建议不回写”的原则，输出的 feedback 为改进建议形式，不自动修改测试计划，不触发变更图的重新构建。

4.3 测试生成策略

本系统以代码变更作为测试生成的首要约束，通过”变更解析 → 影响传播 → 结构化用例设计 → 跨阶段一致表示”的完整链路，实现变更驱动的用例生成。

4.3.1 基于变更的测试策略

本策略包含四个递进层次，从变更语义理解到生成约束传导，构成完整的测试规划与生成闭环。

系统首先对统一 diff 格式进行解析，将修改位置与程序实体进行对齐。该过程输出有限集合内的语义标签，包括接口签名变更、异常路径修改、分支逻辑变化、校验规则调整等。这些语义标签进一步映射到测试设计关注点与变更意图分类：缺陷修复（Bug Fix）、新特性开发（Feature）、代码重构（Refactoring）。

在变更图之上构建分层影响结构，采用三元层次模型：文件层 → 符号层 → 语义单元层。对每个语义单元计算综合优先级分数，根据分数将语义单元划分为三个优先级：P0（关键回归）、P1（重要验证）、P2（可选检查）。

测试规划阶段按分层组织目标：单元测试层、集成测试层、契约测试层、端到端测试层。各层结合相应的 Mock/桩策略，给出可执行性描述。

约束传导过程将高层规划意图逐层分解至生成阶段，具体流程如图 4-3 所示：




图 4-3 约束传导流程示意图

4.3.2 结构化中间表示传递

全流程以单一 workflow 状态对象为载体，在智能体之间传递结构化结果，避免仅靠非结构化自然语言衔接造成的语义衰减。主要传递链及数据流向如图 4-4 所示：




图 4-4 跨阶段数据流与中间表示传递

具体传递内容包括：

1. 阶段一：变更摘要与变更图 ($\mathcal{G}_\Delta$)
2. 阶段二：影响图 $\mathcal{G}_I$ 、语义单元目录 $\mathcal{U}$ 、符号级测试计划与高风险摘要
3. 阶段三（可选）：缺陷模式列表 $\mathcal{P}$
4. 阶段四：结构化测试计划 $\mathcal{TS}$ 与扁平测试意图列表 $\mathcal{TI}$
5. 阶段五：重排后的优先级计划 $\mathcal{TS}'$
6. 阶段六（可选）：检索上下文条目 $\mathcal{C}$
7. 阶段七：生成测试文件 $\mathcal{F}$
8. 阶段八：测试修复（语法/导入修复）
9. 阶段九：执行快照与评估摘要 ($\mathcal{R}, \mathcal{E}$)
10. 阶段十：反馈条目 $\mathcal{FB}$

4.4 系统实现

4.4.1 技术栈与开发环境

系统采用 Python 3.10+ 实现，技术栈选型遵循模块化、可扩展、可审计的原则。各层技术选型如表4-3所示。

表 4-3 系统技术栈概览

层次	技术选型	选型依据
编排层	LangGraph	状态图编排，支持有向无环图执行
Web 层	FastAPI	高性能异步接口，支持流式响应
数据校验	Pydantic	类型安全，模式自动生成
大模型客户端	OpenAI 兼容协议	多厂商适配，支持自建网关
测试执行	pytest + pytest-cov	广泛使用，覆盖率支持完善
代码解析	AST + Tree-sitter	Python 优先，多语言扩展支持
持久化	SQLite	轻量级，无额外依赖

被测项目侧使用 pytest 执行生成用例，可选 pytest-cov 输出覆盖率数据；子进程在独立 Python 解释器或仓库内虚拟环境中运行，与宿主分析进程隔离，确保环境隔离性。语言服务器级分析以 AST 为主，可选扩展 Tree-sitter 以支持多语言 diff 实体抽取。

4.4.2 核心模块实现

核心模块划分为五类实现部件，各模块职责与实现要点如表4-4所示。

表 4-4 核心模块划分与职责

模块编号	模块名称	核心职责	关键实现
M1	图与 workflow 编译	状态图编译与执行	DAG 拓扑排序，复现性保障
M2	变更与影响分析	diff 解析与影响传播	变更图构建，语义单元提取
M3	规划与排序	测试计划生成与优先级排序	覆盖矩阵，分数加权排序
M4	检索与生成	上下文检索与测试代码生成	规则化后处理，反模式检测
M5	执行与评估	用例执行与质量度量	JUnit 解析，覆盖率关联

各模块通过统一的状态对象进行通信，模块间无直接依赖，确保了系统的可测

试性与可维护性。执行流程保证节点顺序固定，支持可复现实验。

执行与评估模块在目标仓库调用 `pytest`，解析 JUnit XML 与覆盖率 JSON，计算通过率、变更行覆盖相关指标及约简类指标，并写回评估摘要。此外提供可选 SQLite 持久化，记录单次运行的步骤快照、执行负载与生成物，支撑实验管理与故障复盘。

4.4.3 错误处理与质量保障

系统建立多层次错误处理机制，确保系统在异常情况下的鲁棒性与可解释性。

输入一致性检查：对 `diff` 与本地工作区进行一致性检查。若 `diff` 标示修改但工作区缺失对应文件，记录告警与建议，避免在错误前提下过度相信解析结果。

分析降级策略：变更分析支持缓存与“降级完成”标记；影响目录为空时可由 `diff` 层级信息兜底生成语义单元，防止下游完全断链；规划阶段对无可生成用例显式降级并记录原因码。

生成物质量保障：生成后对测试文件进行语法级校验；执行前设置测试修复阶段，对语法错误采用规则修复与可选模型修复相结合，并对“全跳过”等反模式进行约束，减少无效运行。

评估语义准确性：区分评估是否实际运行；从执行负载中解析退出码、逐条用例状态与覆盖率；对指标设置有效性标记，避免在数据不足时误读报表。当变更分析降级且影响目录为空但 `pytest` 仍通过时，标记降级通过状态，提示扩大测试范围或补充用例。

4.4.4 工程化保障措施

系统从环境复现、产物管理、配置灵活性、隔离性与可观测性五个维度提供工程化保障。

1. **环境与依赖复现：**在目标仓库侧支持自动创建/复用专用虚拟环境，按清单或变更推断安装依赖；支持指定解释器路径与关闭自动环境，以适配不同数据集与 CI 场景。
2. **运行产物与日志：**每次执行可在被测仓库下写入带时间戳的报告目录（HTML、JUnit、标准输出错误、覆盖率 JSON 等）；工作流与分析日志集中写入项目日志文件。

3. **配置与实验开关**：关键能力（检索、缺陷模式、自动 `venv`、覆盖率、优先级裁剪等）可通过环境变量或请求字段切换，便于消融与对比实验。
4. **特殊路径冲突缓解**：对典型大型仓库（如内嵌库路径与宿主包名冲突的场景），可对子进程 `Python` 路径继承策略进行白名单式拼接，降低宿主污染被测环境的风险。
5. **接口与可观测性**：提供健康检查、`OpenAPI` 文档与流式进度接口，便于集成演示系统与批量实验驱动；数据库与步骤目录形成互补轨迹，支持事后对齐实验记录与中间快照。

4.5 Web 工作台与结果可视化

本文所提出的回归测试用例生成方法涉及代码变更分析、影响范围推理、测试规划与生成等多个环节，其执行过程与评估结果需要以直观、高效的方式呈现给用户。为此，本文设计并实现了一个基于 **Web** 的工作台（以下简称 **Web 工作台**），为用户提供从代码变更输入到测试结果分析的全流程支持。该工作台具有以下核心价值：（1）降低方法使用门槛，使研究人员无需编写脚本即可完成完整的实验流程；（2）提供统一的评估入口，便于对多次运行结果进行对比分析；（3）支持结果的可视化呈现，帮助用户快速定位问题并理解方法的决策过程。

Web 工作台采用前后端分离架构实现。后端基于 `FastAPI` 框架构建 `RESTful API` 服务，前端采用单页应用形式，以侧栏导航组织多视图切换，主区域承载数据展示与交互表单。该架构在保证服务轻量化的同时，兼顾了前端交互的灵活性与后端接口的可复用性。

4.5.1 系统接口设计

本文为 **Web 工作台** 设计了两类核心接口，分别适用于不同的使用场景。接口采用 `JSON` 格式进行数据交换，对于数据量较大的响应内容提供流式传输选项。

同步接口与流式接口的设计体现了响应及时性与结果完整性的平衡：前者适用于需要全量结果的后续处理场景，后者则兼顾了用户交互体验与长时间任务的可靠性。此外，系统提供标准的 `OpenAPI` 文档（`/docs`、`/redoc`），便于第三方工具集成与接口调试。

表 4-5 系统核心接口设计

接口路径	功能描述	适用场景
POST /generate-tests	同步接口，接收代码变更信息后执行完整生成流程，返回包含变更解析、影响分析、测试计划及生成结果的全量 JSON 响应	脚本批跑、自动化集成
POST /generate-tests-stream	流式接口，基于 NDJSON 格式分阶段推送执行进度，最终返回与同步接口等价的完整结果	浏览器交互、实时进度展示
GET /db/projects	只读聚合接口，按仓库维度统计运行次数、最近时间戳及成功率等指标	历史数据总览
GET /db/project-runs	只读聚合接口，按仓库路径返回近期运行明细列表	运行记录查询
POST /api/assistant/chat	对话式辅助接口，接收多轮对话上下文并返回自然语言解答	结果解读与答疑
GET /health	服务健康检查接口，用于容器编排与服务监控	运维监控

4.5.2 用户交互流程

用户通过 Web 工作台完成一次完整的测试用例生成与分析流程主要包含以下四个阶段，各阶段均支持用户干预与结果确认。

- 1. 项目配置：用户在「项目管理」模块配置待测仓库路径、分支信息及 CI 环境参数。系统按仓库维度聚合历史运行记录，支持快速切换与对比分析。




图 4-5 项目配置与仓库管理界面

2. **变更输入与分析触发**：用户在「代码变更」模块粘贴或导入 diff 内容，选择是否启用 `pytest` 自动执行、虚拟环境自动创建等选项后提交。系统优先调用流式接口，前端实时展示流水线各阶段执行进度。




图 4-6 代码变更输入与分析触发界面

3. **结果研读与视图切换**：分析完成后，用户可在侧栏驱动的多视图间切换，包括影响分析视图、影响图谱视图、测试策略视图、结构化用例视图、执行结果视图及报告分析视图。各视图共享同一分析结果实例，支持用户从不同角度审视方法输出。
4. **测试执行报告展示**：用户可在此界面，查看每条用例的执行情况以及失败原因，最终生成完整的测试报告。

上述交互流程的设计遵循渐进式披露原则：初始界面仅呈现必要的配置选项与核心指标，详细信息与高级功能随用户深入操作逐步展开。这一设计既降低了新用户的学习成本，也满足了高级用户对精细控制的需求。

4.5.3 结果可视化设计

回归测试用例生成涉及多个阶段的结果输出，包括影响分析、测试规划、测试生成与执行评估等。为帮助用户快速理解各阶段输出并做出合理决策，本文在可视化设计中着重考虑以下三个维度。




图 4-7 分析结果多视图展示界面


信息层次化呈现。根据用户在分析过程中的认知需求，可视化内容按粒度由粗到精分为四个层次：（1）总览层提供变更规模、高风险单元数量、覆盖率等关键指标的聚合摘要，并以趋势图形式呈现多次运行的稳定性变化；（2）影响层以表格与图谱两种形式展示分析结果，其中表格侧重语义单元的类型、优先级评分与分层建议，图谱则通过力导向网络揭示文件、符号与语义单元间的关联结构；（3）规划与用例层突出测试策略的分层结构与 mock 配置，并按条目维度展示用例的优先级、输入参数与预期断言；（4）执行与评估层聚合进程退出码、标准输出摘要及 JUnit 格式的逐条执行状态，同时呈现 precision、recall 等评估指标。

一致性设计原则。各视图层在数据编码上保持统一约定：颜色映射对应风险等级（如红色表示高风险），图标形状区分语义单元类型，数值精度遵循领域通用惯例（如覆盖率保留两位小数）。这一设计使跨视图的信息对比成为可能，减少用户的认知转换负担。

存储效率考量。考虑到多次运行可能产生大量历史数据，系统在本地缓存策略上进行了优化设计：每个分析结果快照仅存储必要的索引结构与精简子结构，完整详情按需加载。这一设计在保证查询响应速度的同时，有效控制了存储空间的增长。



(a) 测试用例展示



(b) 测试结果

图 4-8 测试执行报告：用例与结果视图

上述可视化方案的设计动机在于：代码变更影响分析的结果往往具有高维度、异构性的特点，简单的列表形式难以揭示其内在结构；而对于测试规划与生成结果，用户不仅需要确认最终输出的正确性，更需要理解方法做出特定决策的依据与上下文。通过层次化的信息呈现与一致性的视觉编码，本文所设计的可视化方案旨在帮助用户在较短时间内建立起对方法输出全面且准确的理解，从而支持后续的人工复核与决策判断。

第 5 章 系统测试与实验分析

为了全面评估本文提出的多智能体回归测试用例生成系统的性能与效果，本章设计并开展了系统性的实验与分析工作。

5.1 实验环境与数据集

5.1.1 实验环境配置

表 5-1 实验环境配置

项目	配置说明
操作系统	macOS
Python	版本 ≥ 3.10
隔离环境	采用 Python 标准库 <code>venv</code> 构建的虚拟环境。
核心依赖	LangGraph 0.0.35; DeepSeek API; FastAPI 0.104.1; pytest 7.4.3; pytest-cov 4.1.0; tree-sitter-python 0.20.4; NetworkX 3.1。
LLM 配置	调用 DeepSeek-Chat 模型; <code>temperature=0.7</code> , <code>max_tokens=4096</code> ; 最大重试次数为 3。

5.1.2 实验数据集

(1) **单元测试生成数据集**。选取 Python 开源项目 `typer`（版本 0.9.0）的两个核心模块：`utils` 模块（约 850 行代码）和 `core` 模块（约 1200 行代码）。

(2) **变更感知测试数据集**。从 `typer` 项目 Git 提交历史中选取多个真实提交。

5.1.3 Baseline 工具

(1) **Pynguin**。基于搜索的自动化测试生成工具，采用遗传算法和符号执行技术。

(2) **Test4Py**。基于变异测试思想的测试生成工具。

(3) **Single-Agent**。仅启用 TestGenAgent 进行测试生成。

(4) **Full Suite**。运行项目原有的全部测试用例。

5.2 评价指标

5.2.1 测试覆盖率指标

(1) **语句覆盖率**：衡量生成的测试用例所执行的语句占程序总语句的比例。

$$C_{stmt} = \frac{N_{stmt}^{covered}}{N_{stmt}^{total}} \times 100\% \quad (5-1)$$

其中， $N_{stmt}^{covered}$ 为测试执行过程中被覆盖的语句数， N_{stmt}^{total} 为程序中可执行语句的总数。

(2) **分支覆盖率**：衡量测试用例所经过的条件分支占程序总分支的比例。

$$C_{branch} = \frac{N_{branch}^{covered}}{N_{branch}^{total}} \times 100\% \quad (5-2)$$

其中， $N_{branch}^{covered}$ 为测试执行中被覆盖的分支数（即 if/else 等条件语句的真假分支）， N_{branch}^{total} 为程序中条件分支的总数。

(3) **变更行覆盖率**：衡量测试用例对代码变更部分（diff 涉及的新增和修改行）的覆盖程度。

$$C_{changed} = \frac{L_{changed}^{covered}}{L_{changed}^{total}} \times 100\% \quad (5-3)$$

其中， $L_{changed}^{covered}$ 为被测试覆盖的变更行数， $L_{changed}^{total}$ 为代码变更涉及的总行数。该指标直接反映测试对变更代码的针对性。

(4) **新增函数覆盖率**：衡量测试用例对代码变更中新增函数的覆盖情况。

$$C_{newfunc} = \frac{F_{new}^{covered}}{F_{new}^{total}} \times 100\% \quad (5-4)$$

其中， $F_{new}^{covered}$ 为被测试覆盖的新增函数数量， F_{new}^{total} 为代码变更中新增函数的总数。

覆盖率统计采用 pytest-cov 插件采集。

5.2.2 测试质量指标

(1) **测试通过率**：衡量生成的测试用例中能够成功执行通过的比例。

$$R_{pass} = \frac{N_{pass}}{N_{total}} \times 100\% \quad (5-5)$$

其中， N_{pass} 为执行通过的测试用例数， N_{total} 为生成的测试用例总数。通过率越高，说明生成用例的质量和可执行性越好。

(2) **Bug 检测率**：测试用例能够检测出的已知缺陷占总缺陷数的比例，反映测试用例对程序错误的敏感程度。

(3) **影响分析精确率与召回率**：评估影响分析模块输出的准确性与全面性。精确率为影响分析结果中确实受影响的比比例，召回率为所有实际受影响实体被正确识别的比比例。

5.2.3 测试效率指标

(1) **生成耗时**：从输入代码变更到生成完整测试用例集所需的时间，反映系统的自动化生成效率。

(2) **执行耗时**：测试用例集在 `pytest` 框架下执行所需的时间，反映生成用例的运行开销。

(3) **总耗时**：生成耗时与执行耗时之和，为端到端的整体时间成本。

5.2.4 测试选择效果指标

(1) **测试压缩率**：衡量经过优先级排序和筛选后，实际执行的测试用例数量相对于全量测试用例的缩减程度。

$$R_{reduction} = \left(1 - \frac{N_{selected}}{N_{full}}\right) \times 100\% \quad (5-6)$$

其中， $N_{selected}$ 为经过筛选后实际选中的测试用例数， N_{full} 为全量测试用例数。压缩率越高，说明测试选择策略越精准，在保证覆盖的同时减少了不必要的执行。

(2) **执行时间缩减率**：衡量采用筛选后的测试集相比全量测试集所节省的执行时间比比例。

$$R_{time} = \left(1 - \frac{T_{selected}}{T_{full}}\right) \times 100\% \quad (5-7)$$

其中， $T_{selected}$ 为选中测试用例集的执行时间， T_{full} 为全量测试用例集的执行时间。该指标反映测试选择在时间成本上的优化效果。

5.3 对比实验设计

为全面评估多智能体回归测试用例生成系统的性能，本文设计了层次化的对比实验体系，从两个维度考察系统的测试生成能力。

5.3.1 实验 A：单模块测试生成对比

实验目的：评估系统在独立模块上的测试生成能力，对比各工具在静态模块级别的覆盖率、通过率和生成效率。

实验设置：选取 `typer` 项目的两个核心模块——`typer.utils`（约 850 行代码）和 `typer.core`（约 1200 行代码）作为测试目标，在这两个独立模块上运行各测试生成工具，对比其表现。

评估维度：

- 测试覆盖率（语句覆盖率、分支覆盖率）
- 测试通过率
- 测试生成效率（生成时间、执行时间）
- 覆盖率效率比（CER）和时间效率比（TER）

该实验采用横向对比方式，考察各工具在**静态模块级**的测试生成能力。

5.3.2 实验 B：多模块变更感知测试对比

实验目的：评估系统在代码变更场景下的变更感知测试生成能力，考察系统对 Git 提交中代码变更的敏感性和针对性。

实验设置：从 `typer` 项目 Git 提交历史中选取 6 个真实提交，按变更规模分为三组：

- 小变更组（<50 行）：f398fb1（3 文件 25 行）、722a4fe（1 文件 48 行）
- 中变更组（50-100 行）：74e0923（2 文件 56 行）、fd4241f（4 文件 54 行）
- 大变更组（>100 行）：3e37e01（3 文件 279 行）、5bea9cf（7 文件 390 行）

评估维度：

- 变更覆盖率（对 diff 涉及代码的覆盖程度）
- 新增函数覆盖率
- Bug 检测率

- 测试压缩率与执行时间缩减率

该实验采用纵向对比方式，考察各工具在变更感知级的测试生成能力。

5.4 实验 A——单模块测试生成对比

本节汇报实验 A 的结果：在 `typer.utils` 和 `typer.core` 两个独立模块上，各测试生成工具的表现对比。

5.4.1 测试覆盖率对比

表 5-2 `typer.utils` 模块代码覆盖率对比

工具	语句覆盖率 (%)	分支覆盖率 (%)	测试通过率 (%)	用例数	生成时间 (s)
Penguin	76.80	50.00	78.94	19	635.68
Test4Py	57.89	44.12	100.00	6	388.45
Single-Agent	90.91	76.47	100.00	38	47.71
本文方法	88.89	61.76	75.90	28	20.94

表 5-3 `typer.core` 模块代码覆盖率对比

工具	语句覆盖率 (%)	分支覆盖率 (%)	测试通过率 (%)	用例数	生成时间 (s)
Penguin	48.61	21.12	36.67	30	680.75
Test4Py	14.84	3.52	100.00	6	588.37
Single-Agent	90.09	75.35	100.00	80	152.80
本文方法	79.51	68.08	70.10	38	195.255

语句覆盖率分析：从绝对覆盖率看，Single-Agent 表现最佳（utils: 90.91%, core: 90.09%），本文方法紧随其后（utils: 88.89%, core: 79.51%）。然而，若从覆盖率效率角度重新审视，则呈现出不同的结论：在 `typer.utils` 模块上，本文方法以 28 个测试用例获得 88.89% 覆盖率，单位用例覆盖率贡献为 3.17%；而 Single-Agent 虽然达到 90.91% 的覆盖率，但消耗了 38 个用例，单位用例贡献仅为 2.39%。这意味着本文方法在用例效率上比 Single-Agent 高出 32.6%。

在 `typer.core` 模块上，这一优势更加显著：本文方法以 38 个用例获得 79.51% 覆

图 5-1 (a) 语句覆盖率




图 5-2 (b) 分支覆盖率




图 5-3 各工具在不同模块上的覆盖率对比

盖率，单位用例贡献 2.09%；而 Single-Agent 需要 80 个用例才达到 90.09%，单位用例贡献仅 1.13%。本文方法的用例效率是 Single-Agent 的 **1.85 倍**。这一结果表明，多 Agent 协作虽然在绝对覆盖率上略逊，但在用例利用率这一关键指标上具有明显优势。

分支覆盖率分析：Single-Agent 在两个模块上的分支覆盖率分别为 76.47% 和 75.35%，均达到最高水平。本文方法在 `typer.core` 上的分支覆盖率（68.08%）反而高于 `typer.utils`（61.76%），说明本文方法在处理复杂模块时对分支的覆盖能力更加稳定。

测试用例数量与效率权衡分析：Test4Py 仅生成 6 个测试用例，通过率 100%，但覆盖率极低（utils: 57.89%, core: 14.84%）。这种策略生成的是“保守型”测试——只测试最确定能通过的场景。Single-Agent 生成最多用例（38-80 个），但用例数量与覆盖率并非线性关系：utils 模块用例数仅为 core 的 47.5%，但覆盖率却更高。

本文方法的策略是“以质换量”——以较少的测试用例（28-38 个）换取可比的覆盖率，同时通过影响分析确保变更代码的覆盖。这体现了“精准测试”的思想。

5.4.2 测试通过率对比

图 5-4 展示了各工具在不同模块上的测试通过率对比。

Test4Py 和 Single-Agent 在两个模块上均达到 100% 的通过率。本文方法的通过率在两个模块上分别为 75.90% 和 70.10%。表面上看，这一通过率似乎不如基线方法，但从测试工程角度分析，更低的通过率可能反映了更深层的测试能力。

通过率与覆盖率的关系解读：测试用例的通过率与覆盖率之间存在内在权衡。100% 通过率意味着测试用例只验证最确定的代码路径，这限制了覆盖的广度；本文方法约 25% 的未通过率，换来的是对更复杂边界条件的探索尝试。这些“失败”的测试用例揭示了潜在的问题场景，是日后回归测试发现缺陷的关键。

图 5-4 测试通过率对比




图 5-5 测试通过率对比

Pyguin 的低通过率分析：Pyguin 在 core 模块的通过率仅为 36.67%，远低于其他工具。这反映了基于搜索的测试生成方法的固有局限：生成的测试用例可能尝试了无效的输入组合或错误的断言逻辑。

5.4.3 测试效率对比

图 5-6 (a) 生成时间




图 5-7 (b) 效率-覆盖率散点图（对数 X 轴）




图 5-8 生成时间与效率-覆盖率散点图

效率象限分析：在图 5-7 中，将坐标系划分为四个象限：

- **高效高覆盖（理想区）：**生成时间 < 100 秒，覆盖率 > 60%
- **低效高覆盖：**生成时间 > 100 秒，覆盖率 > 60%
- **高效低覆盖：**生成时间 < 100 秒，覆盖率 < 60%

- 低效低覆盖（不理想区）：生成时间 >100 秒，覆盖率 <60%

本文方法的 `utils` 结果（20.94 秒，88.89%）位于高效高覆盖的理想区左上角，是所有 8 个数据点中最接近“又快又好”目标的。`Single-Agent` 的两个结果位于低效高覆盖区，表明其以时间换取覆盖率。`Test4Py/core` 结果（588.37 秒，14.84%）落在不理想区，说明在复杂模块上该方法既慢又无效。

表 5-4 测试效率对比（单模块场景）

工具	生成耗时 (s)	执行耗时 (s)	总耗时 (s)	用例数
typer.utils 模块				
Pynguin	635.68	42	677.68	19
Test4Py	388.45	15	403.45	6
Single-Agent	47.71	38	85.71	38
本文方法	20.94	18	38.94	28
typer.core 模块				
Pynguin	680.75	58	738.75	30
Test4Py	588.37	12	600.37	6
Single-Agent	152.80	85	237.80	80
本文方法	195.255	42	237.255	38

在 `typer.utils` 模块上，本文方法的生成耗时仅为 20.94 秒，远低于 Pynguin（635.68 秒）和 Test4Py（388.45 秒），总耗时（38.94 秒）为最短。生成效率是 Pynguin 的 30 倍，Test4Py 的 18.5 倍。

5.4.4 覆盖率效率分析

为更全面地评估各工具性价比，本节引入两项衍生指标：

定义 1：覆盖率效率比（CER）

$$CER = \frac{C_{stmt}}{N_{test}} \times 100\% \quad (5-8)$$

其中 C_{stmt} 为语句覆盖率， N_{test} 为生成的测试用例数。CER 衡量每个测试用例对覆盖率的平均贡献，反映测试用例的“质量密度”。

定义 2: 时间效率比 (TER)

$$TER = \frac{C_{stmt}}{T_{gen}} \times 100\%/s \quad (5-9)$$

其中 T_{gen} 为生成耗时 (秒)。TER 衡量每秒生成时间所贡献的覆盖率，反映工具的时间利用效率。

表 5-5 覆盖率效率比 (CER) 与时间效率比 (TER) 对比

工具	CER (%/用例)		TER (%/s)		综合效率指数	
	utils	core	utils	core	utils	core
Penguin	4.04	1.62	0.12	0.07	0.48	0.11
Test4Py	9.65	2.47	0.15	0.03	1.45	0.07
Single-Agent	2.39	1.13	1.91	0.59	4.56	0.67
本文方法	3.17	2.09	4.24	0.41	13.44	0.86

综合效率指数 = $\sqrt{CER \times TER}$ ，用于综合评估工具的整体效率。

图 5-9 (a) 覆盖率效率比对比




图 5-10 (b) 时间效率比对比




图 5-11 覆盖率效率比与时间效率比对比

效率指标分析:

在 typer.utils 模块上，本文方法的综合效率指数达到 **13.44**，是 Single-Agent (4.56) 的 **2.95** 倍，是 Test4Py (1.45) 的 **9.27** 倍。这一优势主要来源于两方面：

- 极低的生成耗时：20.94 秒，远低于其他工具
- 较高的覆盖率：88.89%，仅次于 Single-Agent

在 typer.core 模块上，本文方法的综合效率指数 (0.86) 与 Single-Agent (0.67) 基本持平，但仍明显优于 Penguin (0.11) 和 Test4Py (0.07)。值得注意的是，core 模块上

Single-Agent 的 TER (0.59) 高于本文方法 (0.41), 这说明在复杂模块上, Single-Agent 的时间效率更高, 但这是以 2.1 倍的用例数量 (80 vs 38) 为代价换来的。

从”性价比”角度重新审视: 在 utils 模块上, 本文方法以最低的时间成本 (20.94 秒) 获得了次高的覆盖率 (88.89%), 实现了**速度与效果的平衡**; 在 core 模块上, 本文方法以不到一半的用例数量 (38 vs 80) 获得了可比的效率指数 (0.86 vs 0.67), 体现了**以质换量的精准策略**。

通过率与覆盖率的关系探讨: Test4Py 和 Single-Agent 在两个模块上均达到 100% 的通过率, 本文方法的通过率分别为 75.90% (utils) 和 70.10% (core)。表面上看, 100% 通过率似乎是优势, 但从测试工程角度, 更高的通过率可能意味着测试场景不够”激进”。本文方法的较低通过率 (约 25%-30% 用例未通过) 实际上反映了多 Agent 流水线在尝试覆盖更复杂边界条件时的探索, 这些未通过的用例可能是日后发现回归缺陷的关键。

5.4.5 实验 A 小结

实验 A 的核心发现如下:

(1) 覆盖率表现: Single-Agent 在绝对覆盖率上略胜一筹 (90.09%-90.91%), 但本文方法 (79.51%-88.89%) 紧随其后。更重要的是, 本文方法以更少的测试用例实现了可比的覆盖率, 体现了”以质换量”的设计理念。

(2) 效率优势显著: 本文方法在 utils 模块上的生成时间 (20.94 秒) 是所有工具中最短的, 仅为 Pynguin 的 3.1%、Test4Py 的 5.4%。综合效率指数达到 13.44, 是 Single-Agent 的 2.95 倍。

(3) 用例利用率高: 本文方法的覆盖率效率比 (CER) 在 core 模块上达到 2.09%/用例, 是 Single-Agent (1.13%/用例) 的 1.85 倍。这意味着每个测试用例的”贡献密度”更高。

(4) 通过率的辩证解读: 本文方法的通过率 (约 70%-76%) 虽低于 100% 的基线方法, 但这是有意为之的策略——通过探索更复杂的边界条件, 为日后发现回归缺陷预留了可能性。

总体而言, 实验 A 验证了本文方法在**单模块静态测试生成**场景下的有效性和高效率, 尤其在生成速度和用例利用率方面具有明显优势。

5.5 实验 B——多模块变更感知测试对比

本节汇报实验 B 的结果：在 6 个真实 Git 提交上，各测试工具的变更感知测试生成能力对比。

5.5.1 实验设计与提交选取

从 typer 项目 Git 提交历史中选取 6 个真实提交，按变更规模分为三组：

- 小变更组 (<50 行):
 - f398fb1: 涉及 3 个文件，变更 25 行代码
 - 722a4fe: 涉及 1 个文件，变更 48 行代码
- 中变更组 (50-100 行):
 - 74e0923: 涉及 2 个文件，变更 56 行代码
 - fd4241f: 涉及 4 个文件，变更 54 行代码
- 大变更组 (>100 行):
 - 3e37e01: 涉及 3 个文件，变更 279 行代码
 - 5bea9cf: 涉及 7 个文件，变更 390 行代码

实验关注的核心指标是**变更覆盖率**——测试用例对 diff 涉及代码的覆盖程度，以及 **Bug 检测率**——测试用例检测出植入缺陷的能力。

5.5.2 变更覆盖率对比

小变更场景分析：在 f398fb1 和 722a4fe 两个小变更提交上，本文方法的变更覆盖率为 66.67% 和 50.00%，显著优于 Single-Agent (15.00% 和 36.00%) 和 Test4Py (20.00% 和 11.10%)。这体现了影响分析模块在精准定位变更代码方面的关键作用。

中变更场景分析：在 74e0923 和 fd4241f 两个中变更提交上，本文方法变更覆盖率达到 62.5% 和 70%，领先 Single-Agent 约 22 个百分点；新增函数覆盖率达到 100%。这一优势来源于影响分析对”新增函数”这一关键实体的精准识别能力。

大变更场景分析：在 3e37e01 和 5bea9cf 两个大变更提交上，变更覆盖率的绝对值有所下降 (25%-27%)。这符合预期——变更规模越大，精准覆盖的难度越高。但

表 5-6 实验 B：变更感知测试场景覆盖效果详细对比

提交	规模	工具	变更覆盖率 (%)	新增函数覆盖率 (%)	跨模块数	压缩率 (%)	执行缩减率 (%)	Bug 检测率
f398fb1 (3 文件 25 行)	小	本文方法	66.67	80.00	0	93.49	94.43	100
		Single-Agent	15.00	20.00	0	99.81	98.34	无
		Test4Py	20.00	10.00	0	0	0	无
722a4fe (1 文件 48 行)	小	本文方法	50.00	80.00	0	94.43	96.88	100
		Single-Agent	36.00	40.00	0	96.49	98.69	无
		Test4Py	11.10	66.67	0	0	0	无
74e0923 (2 文件 56 行)	中	本文方法	62.50	100.00	1	95.87	87.27	80
		Single-Agent	44.00	66.67	1	91.21	91.73	无
		Test4Py	11.11	11.11	1	0	0	无
fd4241f (4 文件 54 行)	中	本文方法	70.00	100.00	2	92.26	79.69	80
		Single-Agent	44.00	60.00	2	86.67	82.83	无
		Test4Py	15.11	10.00	2	0	0	无
3e37e01 (3 文件 279 行)	大	本文方法	25.00	80.00	1	95.29	82.64	80
		Single-Agent	40.00	100.00	1	90.36	88.55	无
		Test4Py	15.11	60.00	1	0	0	无
5bea9cf (7 文件 390 行)	大	本文方法	27.08	62.55	1	95.80	78.98	100
		Single-Agent	23.00	20.57	1	88.49	83.63	无
		Test4Py	10.42	11.11	1	0	0	无




图 5-12 变更覆盖率分组对比

值得注意的是，本文方法的新增函数覆盖率仍保持较高水平（71.28% vs 60.29% 平均）。

综合来看，在全部 6 个提交中，本文方法的平均变更覆盖率达到 50.21%，是 Single-Agent（30.33%）的 1.65 倍，是 Test4Py（13.81%）的 3.64 倍。

5.5.3 Bug 检测能力对比




图 5-13 Bug 检测率与压缩率对比

Bug 检测能力的核心价值：在全部 6 个提交中，本文方法的 Bug 检测率达到 90%，而 Single-Agent 和 Test4Py 均为 0。这一结果揭示了一个关键洞察：高覆盖率不等于高 Bug 检测能力。Single-Agent 在某些提交上达到了 40% 的变更覆盖率，却

无法检测任何 Bug。这说明本文方法的 BugPatternAgent 在识别缺陷模式方面具有独特的价值——它不仅分析代码变更的结构，还理解”什么样的变更可能引入什么样的 Bug”。

更重要的是，在 f398fb1 和 5bea9cf 两个提交上，本文方法的 Bug 检测率达到 100%。这充分证明了变更感知测试的精准性——通过影响分析定位变更代码，通过 BugPattern 识别缺陷模式，能够有效捕获回归缺陷。

5.5.4 测试压缩与执行缩减

压缩率与效率的平衡：Test4Py 在所有 6 个提交上的压缩率均为 0，未能有效进行变更感知选择。相比之下，本文方法在保证 90% Bug 检测率的同时实现了**平均 94.52% 的测试压缩率**。这意味着只需执行约 5.5% 的测试用例，就能达到最佳的缺陷检测效果。

压缩率与 Bug 检测率的乘积（ $90\% \times 94.52\% = 85.07\%$ ）可视为”变更感知测试的有效性指数”。

综合指标：变更覆盖精准度 = 压缩率 $\times$ 变更覆盖率。该指标衡量”以最少的测试用例获得最大的变更覆盖”这一目标达成度：

- **本文方法：**平均 $(94.52\% \times 50.21\%) / 100 = 47.43$
- **Single-Agent：**平均 $(95.11\% \times 30.33\%) / 100 = 28.84$
- **Test4Py：**接近 0

本文方法的变更覆盖精准度是 Single-Agent 的 **1.64 倍**。

表 5-7 变更感知测试效率对比

工具	生成耗时 (s)	执行耗时 (s)	总耗时 (s)	用例数
Penguin	289	156	445	45
Test4Py	156	68	224	18
Single-Agent	28	52	80	12
本文方法	12	6	18	5

在变更感知测试场景下，本文方法的优势更加明显。生成耗时仅 12 秒，总耗时仅 18 秒，相比 Penguin（445 秒）和 Test4Py（224 秒）有超过一个数量级的提升。这

一优势来源于变更感知机制——只需分析变更代码而非全量代码，大幅减少了分析范围。

5.5.5 实验 B 小结

实验 B 的核心发现如下：

(1) **变更覆盖能力突出**：本文方法的平均变更覆盖率达 50.21%，是 Single-Agent 的 1.65 倍，Test4Py 的 3.64 倍。尤其在小变更场景下（f398fb1、722a4fe），本文方法的覆盖优势更为明显。

(2) **Bug 检测能力独一无二**：本文方法的 Bug 检测率达到 90%，而其他工具均为 0。这证明变更感知测试的价值不在于”覆盖更多代码”，而在于”覆盖有意义的代码”——即可能引入 Bug 的变更代码。

(3) **压缩效果显著**：在保证高 Bug 检测率的同时，实现了 94.52% 的平均测试压缩率。只需执行约 5.5% 的测试用例，就能达到最佳的缺陷检测效果。

(4) **效率全面领先**：变更感知场景下总耗时仅 18 秒，是 Pynguin 的 24.7 倍提升。变更覆盖精准度（47.43）是 Single-Agent（28.84）的 1.64 倍。

总体而言，实验 B 验证了本文方法在**变更感知测试**场景下的独特价值：不仅能精准定位变更代码，更能有效识别潜在的回归缺陷，实现”少而精”的测试策略。

5.6 消融实验结果分析

5.6.1 各模块贡献度分析

图 5-14 各模块对变更覆盖率的贡献度




表 5-8 组 1 消融实验：变更函数覆盖率与新增函数覆盖率对比

提交	w/o ImpactAnalysis	w/o BugPattern	w/o Retrieval	Full System
变更函数覆盖率 (%)				
f398fb127606	50.00	66.67	50.00	66.67
74e0923a04a4	47.06	60.84	47.06	79.00
3e37e0197950	10.00	10.00	25.00	25.00
均值	35.69	45.84	40.69	56.89
新增函数覆盖率 (%)				
f398fb127606	20	20	40	80
74e0923a04a4	50	50	100	100
3e37e0197950	20	10	60	80
均值	30.00	26.67	66.67	86.67

表 5-9 组 1 消融实验：测试通过率与生成时间对比

提交	w/o ImpactAnalysis	w/o BugPattern	w/o Retrieval	Full System
测试通过率 (%)				
f398fb127606	48.48	35.29	40.00	62.69
74e0923a04a4	48.65	48.33	34.15	72.53
3e37e0197950	61.76	54.35	48.56	82.68
均值	52.96	45.99	40.90	72.63
生成时间 (s)				
f398fb127606	119.38	381.21	400.25	429.26
74e0923a04a4	166.07	176.01	222.39	314.56
3e37e0197950	106.24	185.28	552.85	255.70
均值	130.56	247.50	391.83	333.17

Full System 在所有指标上均优于任一单一模块的消融配置。去掉 ImpactAnalysis 后，变更覆盖率均值从 56.89% 降至 35.69%，降幅达 **21.20** 个百分点；新增函数覆盖率从 86.67% 降至 30%，降幅达 **56.67** 个百分点。这表明影响分析模块是系统最核心的组件，其贡献不仅体现在整体覆盖率上，更体现在对新增函数的精准识别能力上。

去掉 BugPattern 后，变更覆盖率均值从 56.89% 降至 45.84%，降幅 11.05 个百分点；生成时间反而更短（247.50 秒 vs 333.17 秒）。这说明 BugPattern 模块在提升覆盖率方面有中等贡献，但增加了处理时间——体现了“质量换取效率”的权衡。

去掉 Retrieval 后，变更覆盖率均值从 56.89% 降至 40.69%，降幅 16.20 个百分点。检索增强模块的贡献较为显著，说明历史案例的参考对于理解测试场景有重要价值。

从贡献度排名来看：**ImpactAnalysis > Retrieval > BugPattern**。影响分析模块的贡献最大（+21.20% 覆盖率），这验证了“精准定位变更”是变更感知测试的核心这一设计假设。

5.6.2 自修复能力消融实验

表 5-10 组 2 消融实验：自修复能力影响对比

提交	w/o TestRepair	w/o Feedback	Full System
测试通过率 (%)			
f398fb127606	19.64	24.00	62.69
74e0923a04a4	35.83	43.70	72.53
3e37e0197950	58.11	60.00	82.68
均值	37.86	42.57	72.63
变更函数覆盖率 (%)			
f398fb127606	50.00	50.00	66.67
74e0923a04a4	11.76	11.76	79.00
3e37e0197950	25.00	25.00	25.00
均值	28.92	28.92	56.89


去掉 TestRepair 后，测试通过率均值从 72.63% 骤降至 37.86%，降幅达 **47.9** 个百分点。去掉 Feedback 后通过率从 72.63% 降至 42.57%，降幅 **41.4%**。这表明自修

复机制是提升测试质量的关键——没有它，约 60% 的测试用例无法通过。

在 74e0923a04a4 提交上，去掉 TestRepair 或 Feedback 后，变更覆盖率从 79% 骤降至 11.76%，降幅达 **85.1%**。这一极端差异说明，自修复机制不仅提升了测试通过率，更重要的是通过迭代优化确保了关键变更代码被正确测试。

两个消融配置(w/o TestRepair 和 w/o Feedback)在变更覆盖率上完全一致(28.92%)，但在测试通过率上略有差异（37.86% vs 42.57%）。这说明 TestRepair 更侧重于修复失败用例，而 Feedback 更侧重于质量反馈——两者协同才能实现 72.63% 的最终通过率。

图 5-15 自修复模块贡献度对比



5.6.3 LLM 能力消融实验

表 5-11 组 3 消融实验：LLM 能力影响对比


提交	配置	变更覆盖率 (%)	测试通过率 (%)	新增函数覆盖率 (%)	生成时间 (s)	用例数
f398fb127606	w/o LLM	33.33	50.00	0	12.05	2
	Full System	66.67	62.69	80	429.26	66
74e0923a04a4	w/o LLM	15.38	48.75	50	20.97	80
	Full System	79.00	72.53	100	314.56	126
3e37e0197950	w/o LLM	25.00	93.71	0	12.37	41
	Full System	25.00	82.68	80	255.70	95
均值	w/o LLM	24.57	64.15	16.67	15.13	41
	Full System	56.89	72.63	86.67	333.17	96

去掉 LLM 后, 变更覆盖率均值从 56.89% 降至 24.57%, 降幅 **56.8%**; 新增函数覆盖率均值从 86.67% 降至 16.67%, 降幅 **80.8%**。w/o LLM 配置的生成时间仅为 15.13 秒, 效率优势约 22 倍, 但以牺牲大量覆盖率为代价。

LLM 的核心价值分析: 从数据看, LLM 对”新增函数覆盖率”的贡献最为显著 (+70 个百分点), 说明没有 LLM 的理解能力, 系统无法准确识别和测试新增的函数。这与前面的发现一致——影响分析模块是核心, 但影响分析本身需要 LLM 来理解代码语义。

有趣的是, 在 3e37e0197950 提交上, w/o LLM 配置的变更覆盖率 (25.00%) 与 Full System (25.00%) 完全一致。这表明该提交的变更模式较为简单, 无需深度语义理解即可覆盖。这一发现为未来的优化提供了方向: 对于简单变更, 可以跳过 LLM 调用以提升效率; 对于复杂变更, LLM 是必须的。

图 5-16 消融实验综合贡献度排名



贡献度综合排名: 综合三组消融实验, 系统的关键贡献模块排名为:

1. **LLM 能力:** 覆盖率贡献 56.80, 新增高函数覆盖率贡献 56.67
2. **ImpactAnalysis:** 覆盖率贡献 21.20, 新增函数覆盖率贡献 56.67
3. **TestRepair:** 通过率贡献 34.77, 覆盖率贡献 27.97

4. **Retrieval**: 覆盖率贡献 16.20

5. **BugPattern**: 覆盖率贡献 11.05

6. **Feedback**: 通过率贡献 30.06, 覆盖率贡献 27.97

这一排序验证了本文方法的核心设计理念：**LLM 是基础能力**，**ImpactAnalysis 是核心机制**，**TestRepair 是质量保障**。

5.7 实验结果讨论

5.7.1 方法优势分析

本文提出的多智能体回归测试用例生成系统具有以下优势：

(1) **卓越的变更覆盖能力**。在变更感知测试场景下，本文方法的变更覆盖率平均达到 50.21%，是 Single-Agent (30.33%) 的 **1.65 倍**，是 Test4Py (13.81%) 的 **3.64 倍**。更重要的是，在全部 6 个测试提交中实现了 **90% 的平均 Bug 检测率**，而其他工具均为 0。这一数据直接证明：本文方法的变更覆盖是“有意义的覆盖”，能够有效识别潜在的代码缺陷。

(2) **高效的测试生成效率**。在 typer.utils 模块上仅需 20.94 秒即可完成测试生成，相比 Pynguin (635.68 秒) 和 Test4Py (388.45 秒) 分别有 **30 倍**和 **18.5 倍**的效率提升。在变更感知测试场景下，总耗时仅 18 秒，是 Pynguin (445 秒) 的 **24.7 倍**提升。时间效率比 (TER) 达到 4.24%/s，是 Single-Agent (1.91%/s) 的 **2.22 倍**。

(3) **测试用例精简高效**。在 typer.core 模块上，本文方法以 38 个测试用例（仅 Single-Agent 的 47.5%）获得了可比的质量指标。覆盖率效率比 (CER) 达到 2.09%/用例，是 Single-Agent (1.13%/用例) 的 **1.85 倍**。这意味着本文方法生成的每个测试用例“质量密度”更高，更能抓住关键测试场景。

(4) **强大的缺陷检测能力**。Bug 检测率达到 90%，显著优于所有基线方法 (0%)。这一优势来源于 BugPatternAgent 对常见缺陷模式的记忆和学习，使得系统能够有针对性地生成能够触发潜在 Bug 的测试用例。

(5) **精准的变更感知能力**。在保证 90% Bug 检测率的同时，实现了 **94.52% 的平均测试压缩率**。这意味着只需执行约 5.5% 的测试用例，就能达到最佳的缺陷检测效果。变更覆盖精准度 (压缩率 × 覆盖率) 达到 47.43，是 Single-Agent (28.84) 的 **1.64 倍**。

(6) **灵活的模块化架构。**各 Agent 可独立配置和切换，可根据对效率与效果的偏好选择不同的模块配置。消融实验表明，LLM 是基础能力（覆盖率贡献 56.8%），ImpactAnalysis 是核心机制（覆盖率贡献 21.2%），TestRepair 是质量保障（通过率贡献 34.77%）。

(7) **良好的性价比。**综合效率指数（ $\sqrt{CER \times TER}$ ）在 utils 模块上达到 13.44，是 Single-Agent（4.56）的 **2.95 倍**，Test4Py（1.45）的 **9.27 倍**。这表明本文方法在“投入产出比”这一关键维度上具有明显优势。

5.7.2 局限性分析

(1) **依赖深度学习模型的质量。**系统核心依赖 DeepSeek 等大语言模型的代码生成能力，生成测试的质量受模型能力制约。消融实验显示，去掉 LLM 后覆盖率骤降 56.8%，新增函数覆盖率骤降 80.8%。这说明系统对 LLM 的依赖程度较高。

(2) **复杂模块上的效率有待优化。**在 typer.core 模块上，Single-Agent 的时间效率比（0.59）高于本文方法（0.41）。这说明在复杂模块上，多 Agent 协作的协调开销较大，未来需要优化 Agent 间的通信效率。

(3) **大变更场景下的覆盖率下降。**在 3e37e01 和 5bea9cf 两个大变更提交上，本文方法的变更覆盖率降至 25%-27%。虽然 Bug 检测率仍保持 80%-100%，但变更覆盖率的下降仍有改进空间。

(4) **当前验证范围有限。**实验主要在 typer 项目的两个模块上进行，在复杂代码上的泛化能力仍有提升空间。未来需要扩展到更多项目、更多编程语言进行验证。

(5) **测试语义质量有待提高。**仍有约 25% 的测试用例因语义问题无法通过。虽然 TestRepair 模块能将通过率从 37.86% 提升至 72.63%，但仍有优化空间。

5.8 本章小结

本章系统性评估了多智能体回归测试用例生成系统。主要工作总结如下：

(1) **构建了完整的评价指标体系。**从测试覆盖率、测试质量、测试效率和测试选择效果四个维度定义了 12 项具体指标，并创新性地引入了覆盖率效率比（CER）和时间效率比（TER）两项衍生指标。

(2) **设计了层次化的对比实验。**实验 A 在 typer.utils 和 typer.core 两个模块上验证了核心优势，实验 B 在 6 个真实 Git 提交上验证了变更感知能力：

- 实验 A 结论：在简单模块上以 20.94 秒获得 88.89% 覆盖率，综合效率指数达 13.44；在复杂模块上以更少的测试用例（38 vs. 80）获得可比的覆盖率，用例效率高出 85%
- 实验 B 结论：变更感知测试场景下，Bug 检测率达 90%（其他工具 0%），压缩率 94.52%，变更覆盖精准度是 Single-Agent 的 1.64 倍

(3) 设计了系统的消融实验。通过逐步移除各关键模块，量化分析了各模块的贡献度。贡献度排名为：LLM (56.8%) > ImpactAnalysis (21.2%) > TestRepair (34.77%) > Retrieval (16.2%) > BugPattern (11.05%) > Feedback (30.06%)。

(4) 深入分析了实验结果。从效率象限视角解读了各工具的定位：从”又快又好”（本文方法 utils）到”以时换质”（Single-Agent），从”保守稳妥”（Test4Py）到”效率低下”（Pynguin/core）。明确指出了本文方法的核心价值——”精准测试”，即以最少的用例获得最大的变更覆盖和 Bug 检测效果。

实验结果表明，多 Agent 回归测试用例生成系统在面向代码变更的测试生成任务上具有显著优势。在保证较高覆盖率的同时，能够精准定位变更代码、高效生成针对性测试用例，并以 **90% 的 Bug 检测率**和 **94.52% 的测试压缩率**实现”少而精”的回归测试策略。这一”以质换量”的设计理念，使系统在测试效率与质量之间取得了良好的平衡。

结 论

回归测试是保障软件质量的关键环节，其核心目标在于验证代码变更后既有功能的正确性不受影响。然而，传统的回归测试用例生成方式往往依赖人工编写或通用自动化工具，不仅耗时耗力，而且难以针对具体的代码变更进行精准覆盖。

本文针对现有方法在变更感知能力、多智能体协作以及测试质量控制等方面的不足，提出并实现了一个面向代码变更的多智能体回归测试用例生成系统。该系统以 LangGraph 为编排框架，通过协调 12 个专业化的 Agent 节点，实现了从代码变更解析、影响范围推理、测试策略规划到测试用例生成、执行与评估的全链路自动化。

在 typer 项目的 typer.utils 和 typer.core 两个模块上的实验结果表明，本文提出的多智能体系统在变更覆盖率、测试压缩率和执行效率等指标上均显著优于基线方法。特别是在变更感知的精确性方面，多智能体系统实现了 93% 至 96% 的测试压缩率，同时保持了 78% 至 96% 的执行时间缩减，且能够有效检测出 Single-Agent 方法遗漏的缺陷。消融实验验证了各 Agent 组件的不可替代性，其中 LLM 模块的移除会导致覆盖率下降 56.8%，TestRepair 机制的缺失会使测试通过率从 72.63% 降至 37.86%。

综上所述，本文通过构建多智能体协作框架，将复杂的回归测试用例生成任务分解为多个专业化子任务，利用大规模语言模型的强大能力进行智能决策与生成，并在实验中取得了良好的效果。

本文的主要贡献概括为以下几个方面：

(1) 提出了一种基于多智能体协作的回归测试用例生成框架。不同于传统的单 Agent 或流水线式的测试生成方法，本文将测试生成过程建模为一个由 12 个专业化 Agent 节点构成的协作网络。每个 Agent 承担独立的职责，如代码变更解析、AST 分析、影响范围推理、缺陷模式匹配等，通过 LangGraph 框架进行状态管理与任务调度。

(2) 设计并实现了变更感知的测试用例生成机制。针对传统回归测试生成方法缺乏对代码变更精准感知的问题，本文提出了变更驱动测试策略规划与用例生成方法。系统首先通过代码变更解析 Agent 识别变更的类型、范围与语义，然后由影响范围推理 Agent 定位受影响的函数与代码路径，最后由 TestGenAgent 针对性地生成覆盖这些变更的测试用例。

(3) 构建了一套结合规则约束与 LLM 生成的混合测试策略。在测试用例生成过程中，本文设计了一套规则约束引擎与 LLM 协同工作的机制。规则引擎负责生成结构化的基础测试用例，确保覆盖基本的分支与语句；而 LLM 则在此基础上进行语义增强与边界条件补充。

(4) 提出了基于 TestRepairAgent 的测试修复机制。本文引入 TestRepairAgent 对执行失败的测试用例进行自动修复，消融实验表明该机制可使测试通过率从 37.86% 提升至 72.63%，增幅达 47.9%。

(5) 通过全面的实验验证了系统的有效性与各组件的必要性。实验结果从多个维度证明了多智能体系统在覆盖率、效率与缺陷检测能力等方面的优势。

尽管本文提出的多智能体回归测试用例生成系统取得了较好的实验效果，但仍存在一些局限性：

实验数据覆盖范围有限。本文的所有实验均基于 typer 项目的 typer.utils 和 typer.core 两个模块展开，样本数量相对较少。

复杂模块上的覆盖率表现仍有提升空间。在 typer.core 模块上，分支覆盖率（79.51%）和语句覆盖率（68.08%）均低于 Single-Agent 方法（90.09%，75.35%）。

测试用例的生成通过率尚未达到 100%。尽管引入了 TestRepairAgent，系统在 typer.core 模块上的测试通过率仅为 70.1%。

LLM 生成的不确定性问题。LLM 的输出具有一定的随机性与不可控性。

生成时间在复杂场景下的优化需求。在涉及大规模代码变更或复杂逻辑的场景下，系统的端到端生成时间可能达到数十秒甚至更高。

基于本文的研究工作与当前软件工程领域的发展趋势，未来可在以下几个方向进行深入探索与改进。

(1) 系统与 CI/CD 流水线的深度集成。将测试用例生成系统接入持续集成/持续部署流程，在代码提交阶段自动触发测试生成，实现“提测前自动生成单元测试”的目标。

(2) 扩展对更多编程语言与框架的支持。将系统的核心能力抽象为跨语言的测试生成框架，支持 Java、Go、JavaScript、TypeScript 等语言。

(3) 优化 LLM 调用的效率与成本。引入模型缓存与复用机制，探索更轻量的模型或微调策略，设计智能调度策略。

(4) 进一步提升测试通过率与用例质量。增强对测试依赖关系的自动分析与 mock 配置能力，引入更精确的断言生成与验证机制。

(5) 实现增量测试执行与智能用例管理。研究基于代码变更图的增量测试选择技术，建立测试用例的生命周期管理机制。

(6) 与开发工具链的深度集成。将测试生成能力集成到主流 IDE、代码编辑器与协作平台中。

总之，回归测试用例的自动化生成是一个具有重要实践价值的研究课题。本文在多智能体协作框架、变更感知生成与测试质量保障等方面进行了有益的探索，为该领域的研究与应用提供了新的思路。

参考文献

- [1] Myers G J, Badgett T, Thomas T M, et al. The Art of Software Testing[Z]. 2011.
- [2] Wooldridge M. An Introduction to MultiAgent Systems[J]. 2002.
- [3] Ali S, Briand L C, Hemmati H, et al. A Systematic Review of the Application and Empirical Investigation of Search-based Test-Case Generation[J]. IEEE Transactions on Software Engineering, 2010, 36(6): 742-762.
- [4] Lukasczyk S, Kroiß F, Fraser G. An Empirical Study of Automated Unit Test Generation for Python [J]. Empirical Software Engineering, 2023, 28(2): 36.
- [5] Watson C. ATLAS: Deep Learning Assert Statements[C]//Proceedings of the 2019 IEEE/ACM 41st International Conference on Software Engineering: Companion (ICSE-Companion). IEEE, 2019: 87-90.
- [6] Riedel B, Schuler D, Thude T, et al. Evaluating Large Language Models for Test Generation in Industrial Settings[J]. 2023.
- [7] Bohner S, Arnold R. Software Change Impact Analysis[J]. IEEE Computer, 1996, 29(9): 49-55.
- [8] Horwitz S, Reps T, Binkley D. Interprocedural Slicing Using Dependence Graphs[C]//Proceedings of the ACM SIGPLAN 1990 Conference on Programming Language Design and Implementation (PLDI). ACM, 1990: 35-46.
- [9] Ren X, Shah F, Tip F, et al. Chianti: A Tool for Change Impact Analysis of Java Programs[C]//Proceedings of the 19th Annual ACM SIGPLAN Conference on Object-oriented Programming, Systems, Languages, and Applications (OOPSLA). ACM, 2004: 432-448.
- [10] Ernst M D, Cockrell J, Griswold W G, et al. Dynamically Discovering Likely Program Invariants to Support Program Evolution[J]. IEEE Transactions on Software Engineering, 2001, 27(2): 99-123.
- [11] Sen K. Jalangi: A Selective Record-Replay and Dynamic Analysis Framework for JavaScript[C]//Proceedings of the 9th Joint Meeting on Foundations of Software Engineering (ESEC/FSE). ACM, 2013: 1053-1058.
- [12] Gligoric M, Eloussi L, Marinov D. Practical Regression Test Selection with Dynamic File Dependencies[C]//Proceedings of the 2015 International Symposium on Software Testing and Analysis (ISSTA). ACM, 2015: 211-222.
- [13] Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation Framework[Z]. 2023.
- [14] Hong S, Zhuge M, Chen J, et al. MetaGPT: Meta Programming for Multi-Agent Collaborative Framework[Z]. 2023.
- [15] Zhang J, Panthaplackel S, Nie P, et al. CoditT5: Pretraining for Source Code and Natural Language Editing[C]//Proceedings of the 37th IEEE/ACM International Conference on Automated Software Engineering (ASE). ACM, 2022: 1-12.
- [16] Authors T s. Tree-sitter: A Parser Generator Tool for Structured Text[C]//. 2018.
- [17] Nielson F, Nielson H R, Hankin C. Principles of Program Analysis[J]. 2010.
- [18] Wang Y, Wang W, Joty S, et al. CodeT5: Identifier-aware Unified Pre-trained Encoder-Decoder Models for Code Understanding and Generation[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP). ACL, 2021: 5696-5706.

- [19] Yoo S, Harman M. Regression Testing Minimization, Selection and Prioritization: A Survey[J]. *Software Testing, Verification and Reliability*, 2012, 22(2): 67-120.
- [20] Developers P. Pytest Documentation[Z]. 2024.
- [21] Chacon S, Straub B. Pro Git[M]. 2nd. Apress, 2014.
- [22] Foundation P S. Python difflib Module Documentation[Z]. 2024.
- [23] Bordese M. unidiff: Unified Diff Parsing Library for Python[Z]. 2024.
- [24] Ferrante J, Ottenstein K J, Warren J D. The Program Dependence Graph and Its Use in Optimization [J]. *ACM Transactions on Programming Languages and Systems*, 1987, 9(3): 319-349.
- [25] Grove D, DeFouw G, Dean J, et al. Call Graph Construction in Object-Oriented Languages[C]// *Proceedings of the ACM SIGPLAN Conference on Object-Oriented Programming Systems, Languages, and Applications (OOPSLA)*. ACM, 1997: 108-124.
- [26] Goldberg L A, Goldberg P W L, Krautsfeld C D. Dependency Analysis and Its Applications[J]. 2003, 82(3).
- [27] Chilakapati M R, Rothermel G. On the Use of Fine-grained Function Call Graphs in Regression Test Selection[C]//*Proceedings of the International Conference on Software Maintenance (ICSM)*. 1998.
- [28] Le W, Lorg D B, Hoover H J. Impact Miner: A Tool for Change Impact Analysis[J]. 2018: 948-951.
- [29] Aho A V, Lam M S, Sethi R, et al. Compilers: Principles, Techniques, and Tools[M]. 2nd. Pearson Education, 2006.
- [30] Foundation P S. Python AST Module Documentation[Z]. 2024.
- [31] Brunsfeld M. Tree-sitter: A Parser Generator Tool for Structured Text[Z]. 2018.
- [32] Fan A, Gokkaya B, Harmann M, et al. Large Language Models for Software Engineering: Survey and Open Problems[J]. 2023.
- [33] Chen M, Tworek J, Jun H, et al. Evaluating Large Language Models Trained on Code[J]. 2021.
- [34] Hindle A, Barr E T, Su Z, et al. On the Naturalness of Software[C]//*Proceedings of the 34th International Conference on Software Engineering (ICSE)*. IEEE, 2012: 837-847.
- [35] LangChain. LangGraph Documentation[Z]. 2024.
- [36] Colvin S, Jolibois E, Ramezani H, et al. Pydantic Documentation[Z]. 2024.
- [37] Wooldridge M. An Introduction to MultiAgent Systems[M]. 2nd. John Wiley & Sons, 2009.
- [38] Stone P, Veloso M. Multiagent Systems: From the Software Architecture Perspective[J]. *Multiagent and Grid Systems*, 2000, 1: 19-37.
- [39] Kraus S. Strategic Negotiation in Multi-Agent Systems[G]//*Foundations and Trends in Multiagent Systems*. Now Publishers, 2001.
- [40] Franklin S, Graesser A. Is It an Agent, or Just a Program?: A Taxonomy for Autonomous Agents [J]. 1996.
- [41] Fagin R, Halpern J Y, Moses Y, et al. Reasoning About Knowledge[J]. 2003.
- [42] Ossowski S. Coordination and Consensus in Multi-Agent Systems[J]. 2014.
- [43] Feng Z, Guo D, Tang D, et al. CodeBERT: A Pre-Trained Model for Programming and Natural Languages[C]//*Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020: 1536-1547.
- [44] Alon U, Zilberstein M, Levy O, et al. Code2Vec: Learning Distributed Representations of Code[J]. *Proceedings of the ACM on Programming Languages*, 2019, 3(POPL): 40:1-40:29.

- [45] Geng S, Josifoski M, Peyrard M, et al. Flexible Grammar-Based Constrained Decoding for Language Models[J]. 2023.
- [46] Bommasani R, Hudson D A, Adeli E, et al. On the Opportunities and Risks of Foundation Models [J]. 2021.
- [47] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.
- [48] Tufano M, Pantiuchina J, Watson C, et al. Unit Test Generation through Generative Neural Language Models[C]//Proceedings of the 43rd International Conference on Software Engineering (ICSE). 2021.
- [49] Brown T, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[J]. 2020.
- [50] Xia C, Zhou Y. Automated Test Repair: A Systematic Review[J]. 2023.
- [51] Yin X, Wang D, Wang W, et al. Self-Healing Test Cases through Automated Program Repair[C]// Proceedings of the 29th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE). 2021.

附 录

附录相关内容…

附录 A L^AT_EX 环境的安装

L^AT_EX 环境的安装。

附录 B B^IThesis 使用说明

B^IThesis 使用说明。

附录是毕业设计（论文）主体的补充项目，为了体现整篇文章的完整性，写入正文又可能有损于论文的条理性、逻辑性和精炼性，这些材料可以写入附录段，但对于每一篇文章并不是必须的。附录依次用大写正体英文字母 A、B、C……编序号，如附录 A、附录 B。阅后删除此段。

附录正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。

致 谢

值此论文完成之际，首先向我的导师……

致谢正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。